


**Michał Kaczorowski**

 <https://orcid.org/0009-0007-8164-0796>


Politechnika Łódzka

Wydział Budownictwa, Architektury i Inżynierii Środowiska

Planowanie przestrzenne (II stopień, student)

237193@edu.p.lodz.pl

**Krzysztof Ułamek**

 <https://orcid.org/0000-0001-5528-3739>

Politechnika Łódzka

Wydział Budownictwa, Architektury i Inżynierii Środowiska

Instytut Inżynierii Środowiska i Instalacji Budowlanych

krzysztof.ulamek@p.lodz.pl

## PORÓWNANIE METOD ZBIERANIA DANYCH DLA MIKROSKOPOWEJ SYMULACJI RUCHU W PROGRAMIE VISSIM NA PRZYKŁADZIE PLANOWANIA PRZESTRZENNEGO FRAGMENTU OSIEDLA ŻŁOTNO W ŁÓDZI

**Abstrakt:** Niniejszy artykuł prezentuje studium przypadku porównania metod zbierania danych na potrzeby kalibracji i walidacji mikrosymulacyjnego modelu ruchu ulicznego w programie PTV VISSIM, na przykładzie fragmentu sieci ulicznej osiedla Żłotno w Łodzi. Celem pracy była ocena praktycznej użyteczności i wiarygodności dwóch źródeł danych: ograniczonych pomiarów terenowych oraz komercyjnych danych typu *floating car data* (FCD) dostarczanych przez TomTom MOVE w kontekście modelowania ruchu na potrzeby planowania przestrzennego. Zbudowano i skalibrowano dwa równoległe modele VISSIM, każdy oparty na jednym z analizowanych źródeł danych. Jakość dopasowania modeli oceniono za pomocą szeregu wskaźników, w tym: statystyki GEH, skalowalnego wskaźnika jakości SQV (z ang. *scalable quality value*), pierwiastka błędu średniokwadratowego RMSE (z ang. *root mean square error*) oraz współczynnika korelacji CC (z ang. *correlation coefficient*). Analiza wykazała, że choć oba podejścia mogą prowadzić do akceptowalnych wyników kalibracji, to ich charakterystyki i ograniczenia implikują konieczność świadomego doboru metody zbierania danych, dostosowanej do specyfiki analizowanego obszaru, skali projektu oraz celów planowania przestrzennego.

**Słowa kluczowe:** transport, VISSIM, symulacja, planowanie przestrzenne, *floating car data*, FCD

### COMPARISON OF DATA COLLECTION METHODS FOR MICROSCOPIC TRAFFIC SIMULATION IN VISSIM: A CASE STUDY OF SPATIAL PLANNING IN THE ŻŁOTNO DISTRICT OF ŁÓDŹ

**Abstract:** This paper presents a case study on a comparison of data collection methods for the calibration and validation of a microsimulation traffic model in PTV VISSIM software, based on the example of a section of the street network of Żłotno in Łódź. The aim of the study was to assess the practical usability and reliability of two data sources: limited field measurements and commercial floating car data (FCD) provided by TomTom MOVE, in the context of traffic modelling for urban planning. Two parallel VISSIM models were built and calibrated, each based on one of the analysed data sources. The GEH-statistic, scalable quality value (SQV), root mean square error (RMSE) and correlation coefficient (CC) indices were used to assess the quality of the fit. The analysis showed that although both approaches can lead to acceptable calibration results, their characteristics and limitations imply the need for an informed choice of data collection method, adapted to the specifics of the area under analysis, the scale of the project and the spatial planning objectives.

**Keywords:** transport, VISSIM, simulation, spatial planning, floating car data, FCD

## 1. WPROWADZENIE

Transport miejski stanowi kluczowy element dążenia do zrównoważonego rozwoju obszarów zurbanizowanych. Zrównoważony transport nie ogranicza się

jedynie do kwestii środowiskowych, lecz obejmuje również aspekty społeczne i ekonomiczne, zapewniając różnorodnym grupom dostęp do efektywnego

i wygodnego przemieszczania się w przestrzeni miejskiej (Sokołowicz, 2013). Takie podejście integruje różne środki transportu, minimalizując ich negatywny wpływ na środowisko oraz optymalizując dostępność i funkcjonalność przestrzeni miejskiej.

Jednym z najważniejszych wyzwań współczesnych miast jest spadek popularności transportu zbiorowego przy jednoczesnym wzroście wykorzystania transportu indywidualnego. Przykładem takiego zjawiska może być Łódź, gdzie w latach 2000–2009 liczba pasażerów korzystających z transportu publicznego zmniejszyła się o 42%, co kontrastuje z 7-procentowym spadkiem liczby ludności w tym okresie (Wesołowski, 2013). Dominacja samochodu osobowego w systemie transportowym prowadzi do wielu negatywnych konsekwencji, takich jak: wzrost emisji gazów cieplarnianych, degradacja przestrzeni miejskiej oraz ograniczenie jej dostępności dla użytkowników niezmotoryzowanych. Zjawisko błędnego koła transportu miejskiego, polegające na zmniejszaniu liczby pasażerów komunikacji publicznej, redukcji częstotliwości kursów oraz pogorszeniu stanu infrastruktury, dodatkowo pogłębia ten problem. Mechanizm ten obniża atrakcyjność transportu zbiorowego, co z kolei sprzyja dalszemu wzrostowi popularności transportu indywidualnego, generując koszty, zjawiska kongestii oraz spadek konkurencyjności przestrzeni miejskiej (Ciesielski, 1986).

Kongestia, definiowana jako przeciążenie sieci transportowej wynikające z nierównowagi między popytem a przepustowością, jest jednym z najbardziej palących problemów współczesnego transportu miejskiego i urbanistyki. W literaturze wskazuje się, że jej przyczyny mają charakter strukturalny (niedostateczna przepustowość infrastruktury) oraz incydentalny (zdarzenia drogowe, niekorzystne warunki atmosferyczne) (Żochowska i Karoń, 2012). Konsekwencje kongestii obejmują straty czasu, wzrost kosztów podróży, degradację środowiska oraz negatywny wpływ na zdrowie mieszkańców, co osłabia efektywność funkcjonowania systemu transportowego i obniża jakość życia w miastach.

Transport w miastach powinien cechować się niezależnością, dostępnością i mobilnością (Dominićzak, 2020, s. 112). Zgodnie z zasadami Nowej Urbanistyki kluczowe znaczenie ma promowanie tzw. pieszości (ang. *walkability*), rezygnacja z dominacji transportu indywidualnego na rzecz zbiorowego oraz wykorzystanie środków typu *soft mobility*, np. hulajnóg czy rowerów na minuty, które sprzyjają rozwojowi zintegrowanych ośrodków miejskich. Transport zbiorowy definiowany jest jako wszelkie formy transportu inne niż indywidualne używanie samochodów (Davis i in., 2002).

Tworzenie modeli symulacyjnych, takich jak *Transportowy model symulacyjny miasta Gdańska* (Jamroz i in., 2012), stanowi istotny element współczesnego planowania przestrzennego. Pomimo że wspomniany model nie jest mikrosymulacyjny, umożliwia on analizowanie

dynamicznych interakcji pomiędzy różnymi elementami systemu transportowego oraz ich wpływu na przestrzeń miejską. Symulacje ruchu drogowego pozwalają na wierne odwzorowanie rzeczywistych warunków, co ułatwia identyfikację potencjalnych problemów i weryfikację planowanych rozwiązań przed ich wdrożeniem (Fellendorf i Vortisch, 2011). Kluczowym atutem modeli symulacyjnych jest możliwość przeprowadzania analiz „co jeśli” (ang. *what-if analysis*), które pozwalają na testowanie scenariuszy zmiany układu drogowego, wprowadzania nowych form transportu czy modyfikacji organizacji ruchu.

Zastosowanie modeli symulacyjnych przynosi wymierne korzyści, np. poprawę integracji przestrzennej i wsparcie procesów kształtowania dostępności w miastach. Obecny stan wiedzy dowodzi, że narzędzia, takie jak VISSIM (z niem. *Verkehr in Städten – SIMulationsmodell* – model symulacji ruchu ulicznego w miastach) należą do najbardziej niezawodnych programów wykorzystywanych w badaniach transportu miejskiego (Rrecaj i Bombol, 2015). Poprzez analizę przepływów transportowych oraz ich wpływu na dostępność różnych obszarów miasta możliwe jest projektowanie rozwiązań wspierających rozwój centrów miejskich i poprawę jakości życia mieszkańców (Davis i in., 2002).

Analiza literatury obrazuje mnogość podejść oraz metod zbierania danych do symulacji mikroskopo- wych. Badacze w zależności od typu obszaru badań (fragment autostrady, zbiór skrzyżowań, fragment sieci ulic miejskich), jego wielkości i złożoności decydują się na zastosowanie różnych technik oraz metod pozyskiwania danych (Auberlet i in., 2014; Park i Won, 2006b). Tradycyjną i stosunkowo prostą metodą jest bezpośrednia obserwacja i rejestracja wideo skrzyżowań i/lub wybranych odcinków ulic przez zespół obserwatorów terenowych. Pozwala to na późniejsze szczegółowe odtwarzanie i analizę relacji skrętnych, natężeń ruchu oraz struktury rodzajowej pojazdów. Pomimo intuicyjnej prostoty implementacji takie rozwiązanie jest obciążone istotnymi wadami, do których należą: czasochłonność przedsięwzięcia w wymiarze od kilku do kilkunastu godzin spędzonych na pomiarach terenowych w ciągu wielu dni oraz późniejsza analiza wideo, a także konieczność zaangażowania wielu osób w zależności od stopnia skomplikowania sieci (Hidas i Wagner, 2004). Kolejną kategorią metod jest wykorzystanie dedykowanej infrastruktury pomiarowej, zainstalowanej bezpośrednio w jezdni lub w jej bezpośrednim sąsiedztwie. Do najczęściej stosowanych instrumentów tego typu zalicza się: pętle indukcyjne, detektory mikrofalowe (radary) oraz kamery wideo (w tym systemy automatycznego rozpoznawania tablic rejestracyjnych ANPR – z ang. *automatic number plate recognition*) (Gaca i in., 2014). Instrumenty te, zwłaszcza pętle i radary, ze względu na relatywnie niski koszt jednostkowy oraz możliwość ciągłego, automatycznego

gromadzenia informacji o natężeniach i prędkościach punktowych, są popularne i szeroko stosowane w systemach zarządzania ruchem, a uzyskane wyniki mogą być wykorzystywane również do kalibracji modeli. W ostatnich latach coraz powszechniejsze staje się zbieranie danych z urządzeń mobilnych, takich jak: telefony komórkowe, urządzenia Bluetooth czy odbiorniki GPS. Pomiarów dostarczane dzięki technologii FCD (z ang. *floating car data*), służącej do wyznaczania średniej prędkości i czasu przejazdu na badanym odcinku sieci drogowej, pozyskiwane pasywnie z urządzeń podłączonych do sieci (np. smartfonów z aplikacjami nawigacyjnymi, urządzeń telemetrycznych w pojazdach), podlegają następnie przetwarzaniu oraz anonimizacji. Na podstawie tak zebranych danych komercyjni dostawcy, jak: Google, TomTom czy HERE, są w stanie generować różnorodne produkty informacyjne. Dla użytkowników końcowych są to często mapy natężenia ruchu w czasie rzeczywistym oraz przewidywane czasy przejazdu. Jednocześnie na potrzeby analityczne i modelowania firmy te dostarczają zagregowane obserwacje historyczne, obejmujące średnie prędkości lub czasy przejazdu dla poszczególnych segmentów sieci drogowej w określonych interwałach czasowych dla różnych pór dnia i dni tygodnia, a nawet estymowane na ich podstawie macierze relacji źródło–cel. Zbiory te, ze względu na szerokie pokrycie przestrzenne i czasowe, stają się coraz ważniejszym źródłem informacji dla modelowania transportu (Kucharski, 2009). Perspektywnym kierunkiem wydaje się również stosowanie i fuzja danych z wielu źródeł, co ma na celu zwiększenie dokładności i wiarygodności materiałów wejściowych (Del Serrone i in., 2023; Gitahi i in., 2020), a tym samym poprawę jakości i rzetelności wyników uzyskiwanych z modeli mikrosymulacyjnych.

Niezależnie od wybranej technologii etap uzyskania odpowiednich danych empirycznych jest fundamentalnym elementem całego procesu budowy i oceny modelu mikrosymulacyjnego. Badacze wykorzystują szerokie spektrum metod do zbierania informacji o rzeczywistych warunkach ruchu, dostosowując je do specyfiki analizowanego problemu, dostępnych zasobów oraz wymaganego poziomu szczegółowości (Park i Won, 2006b). Co istotne, często stosuje się różne techniki pomiarowe do pozyskania odmiennych typów danych, które następnie służą jako podstawa do kalibracji lub walidacji różnych aspektów modelu. Przykładowo, informacje określające natężenie ruchu, kluczowe do odwzorowania popytu i przepustowości, mogą być zbierane za pomocą pętli indukcyjnych lub analizy nagrań wideo, a ich zgodność z wynikami symulacji oceniana jest zazwyczaj za pomocą wskaźnika GEH, który stanowi empiryczną miarę błędu stosowaną w modelowaniu transportu do porównywania obserwowanych i symulowanych natężeń ruchu. Wartość GEH poniżej 5,0 jest powszechnie akceptowana jako

wskazująca na dobre dopasowanie modelu. Z kolei odczyty dotyczące prędkości lub czasów przejazdu, niezbędne do kalibracji parametrów behawioralnych i oceny płynności ruchu, mogą pochodzić z pomiarów radarowych, systemów FCD lub pojazdów testowych, a ich dopasowanie do modelu jest często weryfikowane za pomocą wskaźników pierwiastka błędu średniokwadratowego RMSE (z ang. *root mean square error*), średniego błędu bezwzględnego MAE (z ang. *mean absolute error*), średniego bezwzględnego błędu procentowego MAPE (z ang. *mean absolute percentage error*) czy współczynnika korelacji  $R^2$  (So i in., 2016). Taka dywersyfikacja, zarówno metod zbierania danych, jak i stosowanych miar efektywności MoE (z ang. *measures of effectiveness*), wydaje się podejściem właściwym (Auberlet i in., 2014). Wykorzystanie wielu różnych typów materiałów referencyjnych (np. jednoczesne porównywanie natężeń, prędkości i czasów przejazdu) pozwala na bardziej kompleksową i rzetelną ocenę jakości modelu, dając większą pewność, że odwzorowuje on rzeczywistość w sposób zrównoważony, a nie tylko pod kątem jednego, wybranego wskaźnika. Chociaż integracja informacji z tak różnorodnych źródeł stanowi wyzwanie, jest to niezbędne do budowy wiarygodnych i użytecznych narzędzi symulacyjnych wspierających procesy decyzyjne w transporcie.

Obszerna literatura przedmiotu jest poświęcona modelowaniu mikrosymulacyjnemu, jednak przegląd dostępnych publikacji ujawnia, że znaczna część badań koncentruje się na analizie ruchu na drogach wyższych klas, takich jak autostrady i drogi ekspresowe, lub na szczegółowym modelowaniu pojedynczych, izolowanych skrzyżowań. Zdecydowanie mniej uwagi poświęca się natomiast kompleksowemu modelowaniu i kalibracji symulacji dla sieci ulic miejskich (Al-Msari i in., 2024; Mohan i in., 2021; Rrecaj i Bombol, 2015). Ta dysproporcja jest istotna, ponieważ właśnie w środowisku miejskim narzędzia mikrosymulacyjne mają ogromny potencjał we wspieraniu procesów planowania przestrzennego i projektowania infrastruktury. Skuteczna integracja analiz transportowych z planowaniem miejscowym wymaga jednak wiarygodnych modeli ruchu, zdolnych do precyzyjnego odwzorowania lokalnych warunków. Kluczowym wyzwaniem w tym kontekście jest etap kalibracji i walidacji modeli mikrosymulacyjnych dla sieci miejskich, który fundamentalnie zależy od jakości, dostępności i adekwatności informacji wejściowych. Jak pokazuje praktyka, stosuje się różne metody pozyskiwania tych danych, od tradycyjnych pomiarów terenowych po nowoczesne technologie, takie jak FCD.

W Polsce liderem w liczbie opracowań, zarówno w skali makro, jak i mikro, jest Warszawa, gdzie symulacja jest wykorzystywana do tworzenia scenariuszy modernizacji, budowy sieci transportowych, sporządzania planów miejscowych oraz studiów

uwarunkowań i kierunków zagospodarowania przestrzennego (SISKOM – Stowarzyszenie Integracji Stołecznej Komunikacji, 2025). W ostatnim czasie VISSIM był wykorzystywany w Gdańsku do oceny skrzyżowania z ruchem okrężnym (Kłos i Sobota, 2019) i w Łodzi do ewaluacji wariantów rozbudowy dróg w obszarze strefy przemysłowej (Siwek, 2024). Brakuje jednak w polskiej literaturze przedmiotu kompleksowych opracowań porównujących efektywność i wiarygodność różnych metod w procesie kalibracji modeli dla struktury układu komunikacyjnego obsługującego tkankę miejską o dominującej funkcji mieszkaniowej ze wskazaniem na ich użyteczność w planowaniu przestrzennym.

Celem artykułu jest analiza porównawcza dwóch źródeł danych – ograniczonych pomiarów terenowych i komercyjnych danych dostarczanych przez TomTom MOVE. Praca ma na celu ocenę ich użyteczności i wiarygodności w kontekście modelowania ruchu na potrzeby planowania przestrzennego na przykładzie terenu osiedla Złotno w Łodzi. Wnioski z analiz mają prowadzić do określenia obszaru użyteczności porównywanych metod zbierania danych dla mikrosymulacji, w zależności od kontekstu i potrzeb praktyki planowania przestrzennego.

## 2. METODOLOGIA ORAZ MATERIAŁ BADAWCZY

### 2.1. PODSTAWY TEORETYCZNE MIKROSYMULACJI

Współczesne planowanie i zarządzanie systemami transportowymi w złożonych środowiskach miejskich wymaga stosowania zaawansowanych narzędzi analitycznych. Wśród nich szczególne miejsce zajmują modele mikrosymulacyjne oferujące wysoki poziom szczegółowości w odwzorowaniu dynamiki ruchu drogowego (Park i Won, 2006b). Umożliwiają one analizę interakcji poszczególnych uczestników ruchu, co jest kluczowe do oceny funkcjonowania skomplikowanych układów drogowych, do których zalicza się: skrzyżowania z sygnalizacją, węzły czy odcinki o intensywnym przeplataniu. Model mikrosymulacyjny to narzędzie symulacji komputerowej, które opisuje system transportowy na najniższym poziomie, śledząc ruch każdego pojedynczego pojazdu w sieci w krótkich, dyskretnych krokach czasowych (zazwyczaj rzędu 0,1–1,0 sekundy) (Dybicz, 2009). W każdym dyskretnym kroku czasowym symulacji aktualizowane jest położenie, prędkość oraz stan wszystkich obiektów w sieci. Operacje te bazują na zaimplementowanych mechanizmach opisujących zachowania poszczególnych uczestników ruchu.

Fundamentem działania modeli mikrosymulacyjnych są modele matematyczne odwzorowujące

procesy decyzyjne kierowców. Do najczęściej stosowanych w tej dziedzinie należy: „Model [p]sychologiczny ([p]sychological [m]odel): Ten model bada psychologiczne aspekty zachowania kierowców. Zakłada, że kierowcy podejmują decyzje na drodze na podstawie swojego poziomu uwagi, stresu, zmęczenia i innych czynników psychologicznych” (Sroczyński, 2023, s. 13–14). Modele mikroskopowe możemy sklasyfikować na podstawie zachowań kierowców i wyróżnić wśród nich modele jazdy za liderem (ang. *car-following model*), w tym psychofizyczne modele podążania za liderem, gdzie reprezentatywnym przykładem jest model Wiedemanna 74, uwzględniający progi percepcji i reakcji kierowcy. Mają one charakter stochastyczny, co oznacza, że uwzględniają losową zmienność w zachowaniach poszczególnych kierowców, np. różnice w pożądanej prędkości, czasie reakcji, agresywności (Sroczyński, 2023).

Istnieje wiele pakietów oprogramowania realizujących idee mikrosymulacji. Jednym z najczęściej stosowanych, zarówno w praktyce inżynierskiej, jak i badaniach naukowych, jest PTV VISSIM (Park i Won, 2006b). Oprogramowanie to implementuje wspomniane wcześniej modele zachowań (domyślnie modele Wiedemanna 74 i 99) i pozwala na szczegółowe kodowanie geometrii sieci, ustawianie sygnalizacji świetlnej, definiowanie różnych typów pojazdów, transportu publicznego, pieszych i rowerzystów. Program VISSIM umożliwia wizualizację symulacji w 2D i 3D oraz zbieranie szerokiego zakresu MoE.

### 2.2. SCHEMAT WYKONYWANIA MIKROSYMULACJI

Skuteczne wykorzystanie modeli mikrosymulacyjnych w analizie i planowaniu systemów transportowych jest ściśle uzależnione od ich dokładności i wiarygodności. Osiągnięcie wiarygodnych wyników wymaga zastosowania systematycznego podejścia obejmującego kolejne etapy budowy, kalibracji i walidacji modelu (El Esawey i Sayed, 2011; So i in., 2016). Wobec tego kluczowe jest zdefiniowanie klarownej strategii opartej na logicznych i sekwencyjnych krokach.

Proces modelowania rozpoczyna się od budowy modelu bazowego, odzwierciedlającego fizyczne i operacyjne charakterystyki analizowanej sieci drogowej. Ten etap obejmuje precyzyjne zakodowanie geometrii sieci (łącznic, łączników, skrzyżowań) w oprogramowaniu VISSIM na podstawie danych GIS, ortofotomap, modeli 3D i weryfikacji terenowej. Następnie definiowane są typy i klasy pojazdów, ich kompozycja w strumieniu ruchu oraz modelowane są elementy sterowania ruchem, takie jak sygnalizacja świetlna czy zasady pierwszeństwa (So i in., 2016). Równolegle prowadzona jest zbiórka danych terenowych, obejmująca zarówno dane fundamentalne (niezbędne do budowy modelu), jak i MoE, np. natężenia ruchu, prędkości, czasu przejazdu

czy długości kolejek, które posłużą do późniejszej kalibracji i walidacji (Park i Qi, 2005).

Kolejnym istotnym etapem jest kalibracja modelu mająca na celu dostrojenie wewnętrznych parametrów symulacji (np. parametrów modelu podążania za liderem, logiki zmiany pasa) w taki sposób, aby wyniki generowane przez model jak najwierniej odpowiadały obserwacjom terenowym (Stevanovic i in., 2008). Jak sugerują El Esawey i Sayed (2011), kalibracja w modelach średnich i dużych sieci często koncentruje się na trzech komponentach: estymacji popytu (np. macierzy źródło–cel), kalibracji wyboru trasy (w modelach z rozkładem dynamicznym) oraz kalibracji parametrów zachowań kierowców. Jest to proces iteracyjny, wymagający zdefiniowania kryteriów oceny, wyboru parametrów do kalibracji i ich dopuszczalnych zakresów, ustawienia akceptowalnych progów błędu oraz wielokrotnego uruchamiania symulacji i oceny wyników.

Ostatnim niezbędnym krokiem jest walidacja modelu. Polega ona na ocenie jakości skalibrowanego modelu przy użyciu niezależnego zestawu danych terenowych, który nie był wykorzystywany podczas procesu kalibracji. Ten etap weryfikuje zdolność modelu do generalizacji i poprawnego odwzorowania warunków ruchu innych niż te, do których był bezpośrednio dostrajany, co jest zasadnicze dla jego wiarygodności w zastosowaniach predykcyjnych.

W omawianym badaniu model został poddany kalibracji i walidacji. Jako MoE zdefiniowano dwa kluczowe wskaźniki: natężenie ruchu oraz prędkość pojazdów. Aby sprawdzić, w jakim stopniu symulacja odpowiada warunkom rzeczywistym, obliczono wskaźnik GEH oraz skalowaną wartość jakości SQV (z ang. *scalable quality value*) dla natężeń ruchu (Friedrich i in., 2019; Yang i in., 2016). W przypadku prędkości pojazdów wykorzystano powszechnie stosowane miary statystyczne: RMSE oraz CC (Florida Department of Transportation, 2014; Washington State Department of Transportation, 2014). Przyjęto następujące kryteria kalibracji: wartość średnia GEH poniżej 5,0 dla całego zbioru analizowanych odcinków przy zachowaniu GEH poniżej 5 dla więcej niż 85% porównywanych odcinków (Washington State Department of Transportation, 2014), wartość średnia SQV powyżej 0,80 dla całego zbioru analizowanych odcinków przy zachowaniu SQV powyżej 0,80 dla więcej niż 85% porównywanych odcinków, wartości RMSE mniejsze od 15% oraz współczynnik korelacji wyższy od 0,85 dla sumy średniej prędkości ze wszystkich mierzonych odcinków. Uzyskanie takich parametrów świadczy o akceptowalnej zgodności modelu. Wzory wykorzystanych w akapicie wskaźników są następujące:

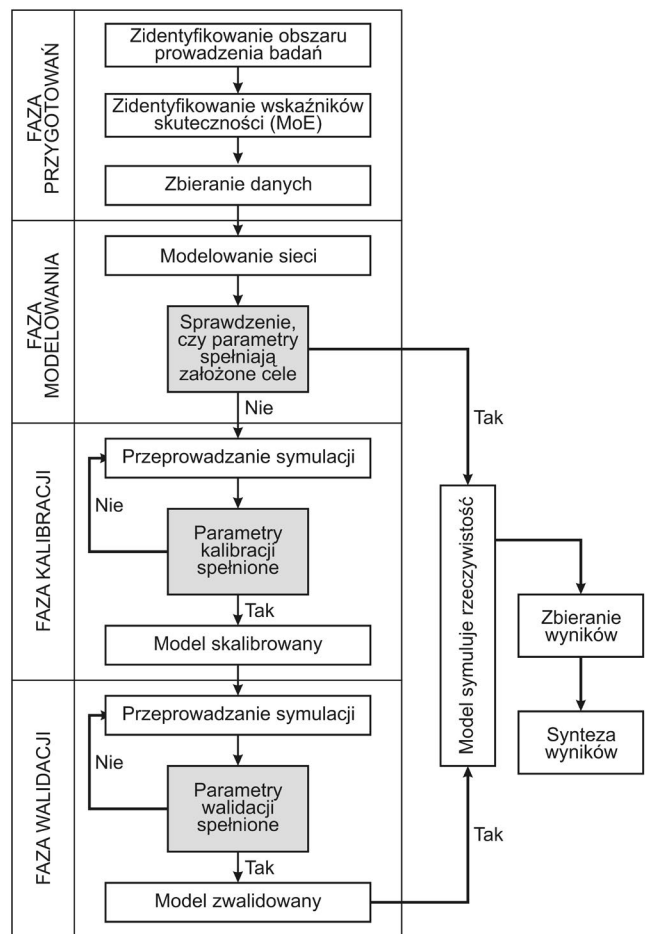
$$GEH = \sqrt{\frac{2(M - C)^2}{M + C}} \quad (1)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n \left( \frac{C_i - M_i}{C_i} \right)^2} \quad (2)$$

$$SQV = \frac{1}{1 + \sqrt{\frac{(M - C)^2}{f * C}}} \quad (3)$$

gdzie:  $i$  = indeks obserwacji,  $M$  – wartość modelowana,  $C$  – wartość obserwowana,  $f$  – współczynnik ustalony w przypadku mierzenia natężenia godzinowego na 1000 (Friedrich i in., 2019).

Rysunek 1 przedstawia schemat graficzny prowadzenia badania.



Rysunek 1. Schemat prowadzenia badania  
Źródło: Abdeen i in. (2023)

### 2.3. OBSZAR BADAŃ

Zgodnie z raportem *TomTom Traffic Index* (2024) Łódź plasuje się na 7. miejscu na świecie i 1. w Polsce pod względem poziomu kongestii drogowej. Dane wskazują, że średni czas przejazdu dystansu 10 km w mieście wynosi ok. 28 minut podczas szczytu porannego i aż 35 minut w szczycie popołudniowym. Przekłada się to

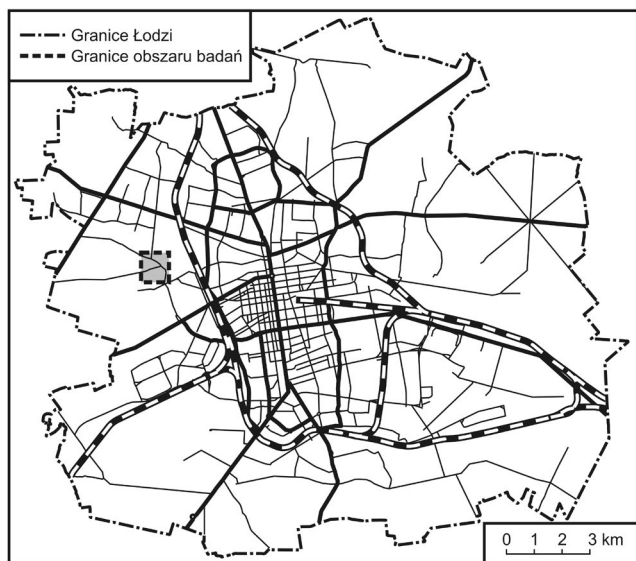
na znaczące straty czasu dla mieszkańców. Z analizy statystyki z 2024 r. (TomTom, 2024) wynika, że kierowca w Łodzi stracił 110 godzin z powodu zatłoczenia podczas podróży na dystansie 10 km, co stanowi wzrost o ponad 5 godzin w porównaniu do roku poprzedniego (TomTom, 2023). Wskaźniki te czynią Łódź szczególnie interesującym obszarem do badań nad problematyką kongestii i efektywnością systemów transportowych. Jednocześnie wskazują one na znaczenie prac planistycznych ukierunkowanych na mitygację zatłoczenia. Analiza powiązań między strukturą przestrzenną miasta a generowanym ruchem, wspierana takimi narzędziami jak mikrosymulacja, wydaje się fundamentalna do opracowania skutecznych strategii poprawy warunków komunikacyjnych w Łodzi.

Obszar badania znajduje się w całości w strefie opisanej w *Studium uwarunkowań i kierunków zagospodarowania przestrzennego miasta Łodzi* jako M3, czyli w strefie ogólnomiejskiej o przeznaczeniu funkcjonalno-przestrzennym terenu pod zabudowę mieszkaniową, leży w bezpośrednim sąsiedztwie parku im. J. Piłsudskiego. W *Studium* obsługa komunikacyjna analizowanego fragmentu Złotna, podłączenie do sieci miejskiej oraz tranzyt są realizowane ulicami Krakowską i Rąbieńską. Kierunki rozwoju przewidują również rozbudowanie sieci poprzez dodanie drogi na wschód od ul. Stare Złotno (Miejska Pracownia Urbanistyczna w Łodzi, 2018).

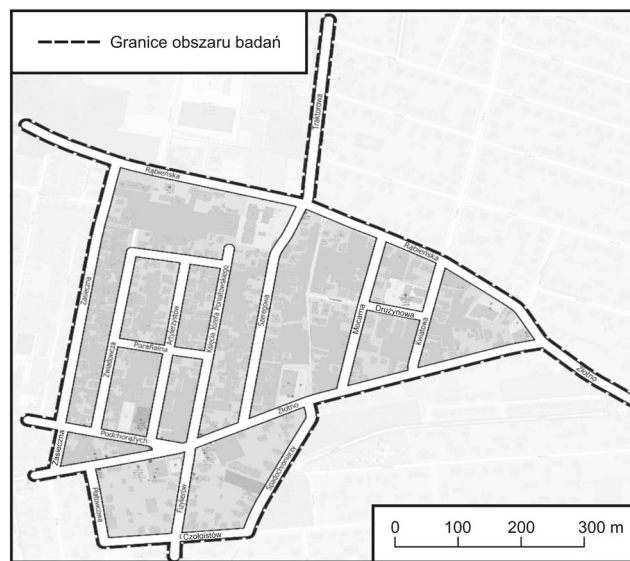
Teren będący przedmiotem niniejszego opracowania jest obecnie niedostatecznie obsługiwany komunikacyjnie w kierunku północ-południe, w którym można przejechać trasą prowadzącą ulicami Krakowska-Rąbieńska-Traktorowa. Dochodzi tam jednak często do kongestii, a alternatywne połączenia, czyli ul. Szczecińska, S14 i al. Włókniarzy, są odległe o ok. 3 km, co powoduje, że ten ciąg komunikacyjny realnie nie ma zamiennika. Zmiany w układzie transportowym powinny

zapewnić dostępność komunikacyjną, szczególnie poprzez dodanie alternatywnej trasy dojazdu północ-południe do omawianego obszaru. Rozwinięcie układu transportowego o nowe drogi o charakterze lokalnym mogłoby poprawić skomunikowanie tego miejsca oraz wspomóc proces tworzenia się centrum osiedlowego Złotna. Lokalizację terenu badań na tle miasta Łodzi pokazano na rysunku 2.

W ramach badania poddano szczegółowej analizie wyselekcjonowany fragment osiedla Złotno. Wybór tego konkretnego obszaru był podyktowany unikatowym połączeniem cech typowych dla stref zabudowy mieszkaniowej jednorodzinnej z jednoczesnym występowaniem specyficznych, rzadziej spotykanych uwarunkowań geometrycznych układu drogowego, co czyni go szczególnie interesującym przypadkiem studialnym. Analizowany fragment charakteryzuje się dominującą zabudową jednorodzinną, w większości wolnostojącą, z punktami usługowymi zlokalizowanymi wzdłuż głównych ciągów komunikacyjnych. Obserwuje się tu również wysoki stopień motoryzacji indywidualnej i znaczny udział podróży samochodowych w dojazdach do pracy, co jest typowe dla tego rodzaju struktur osadniczych (Mężyk i Zamkowska, 2019) i pozwala na odniesienie wniosków z badania do szerszego kontekstu podobnych terenów miejskich. Wybrany fragment Złotna cechuje się dodatkowo nietypowymi rozwiązaniami geometrycznymi układu drogowego. Znaczna część skrzyżowań nie ma standardowego, prostokątnego układu wlotów, co może wpływać na czytelność i bezpieczeństwo manewrów. Nieregularna geometria, stanowiąca potencjalne źródło problemów w układzie transportowym, jest też wyzwaniem przy modelowaniu. Ta kombinacja typowych cech osiedla o niskiej intensywności zabudowy z nietypowymi uwarunkowaniami infrastrukturalnymi



Rysunek 2. Lokalizacja obszaru badań w Łodzi  
Źródło: opracowanie własne

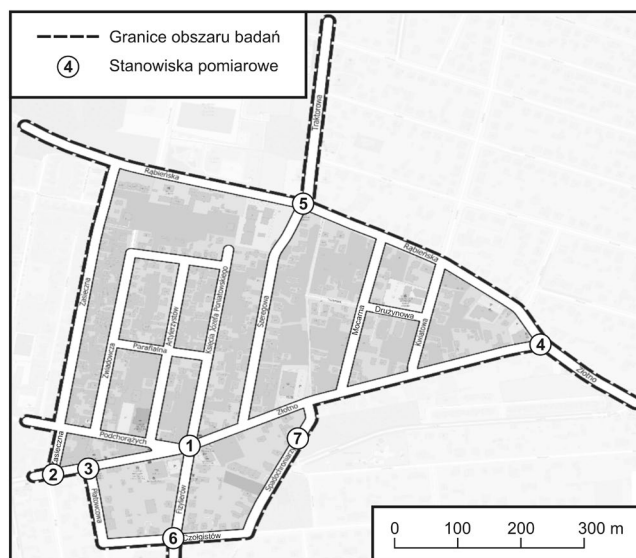


Rysunek 3. Plan badanego fragmentu osiedla Złotno  
Źródło: opracowanie własne

stanowiła przesłankę do wyboru tego obszaru jako reprezentatywnego, a jednocześnie interesującego pola badawczego do analizy porównawczej metod zbierania danych na potrzeby mikrosymulacji ruchu. Gotowy model stał się dodatkowo podstawą do porównania różnych wariantów zmian, które miały na celu usunięcie problemu braku wystarczającej liczby połączeń komunikacyjnych. Prezentacja wyników tych analiz wykracza jednak poza zakres tej pracy. Obszar badań przedstawiono na rysunku 3.

## 2.4. ZBIERANIE DANYCH

W celu ustalenia wielkości ruchu drogowego dokonano pomiarów na wybranych skrzyżowaniach oznaczonych numerami 1–7 na rysunku 4. Dane zebrano za pomocą techniki nagrań wideo, które następnie obejrzano kilkakrotnie w celu uzyskania informacji. Mierzono relacje skątne na skrzyżowaniach, rozróżniano rodzaj pojazdu oraz typ manewru wykonany na skrzyżowaniu (skręt w lewo, jazda na wprost, skręt w prawo). Analizowano również prędkość pojazdów.



Rysunek 4. Skrzyżowania ulic na terenie badanego fragmentu osiedla Złotno objęte pomiarem ruchu 17 listopada 2023 r.  
Źródło: opracowanie własne

Rodzajową strukturę ruchu na badanym terenie osiedla Złotno przedstawiono w tabeli 1.

Tabela 1. Rodzajowa struktura ruchu na badanym terenie osiedla Złotno

| Rodzaj pojazdu |           | Odsetek |
|----------------|-----------|---------|
| Samochód       | osobowy   | 91,32   |
|                | dostawczy | 6,07    |
|                | ciężarowy | 1,16    |
| Autobus        |           | 1,45    |

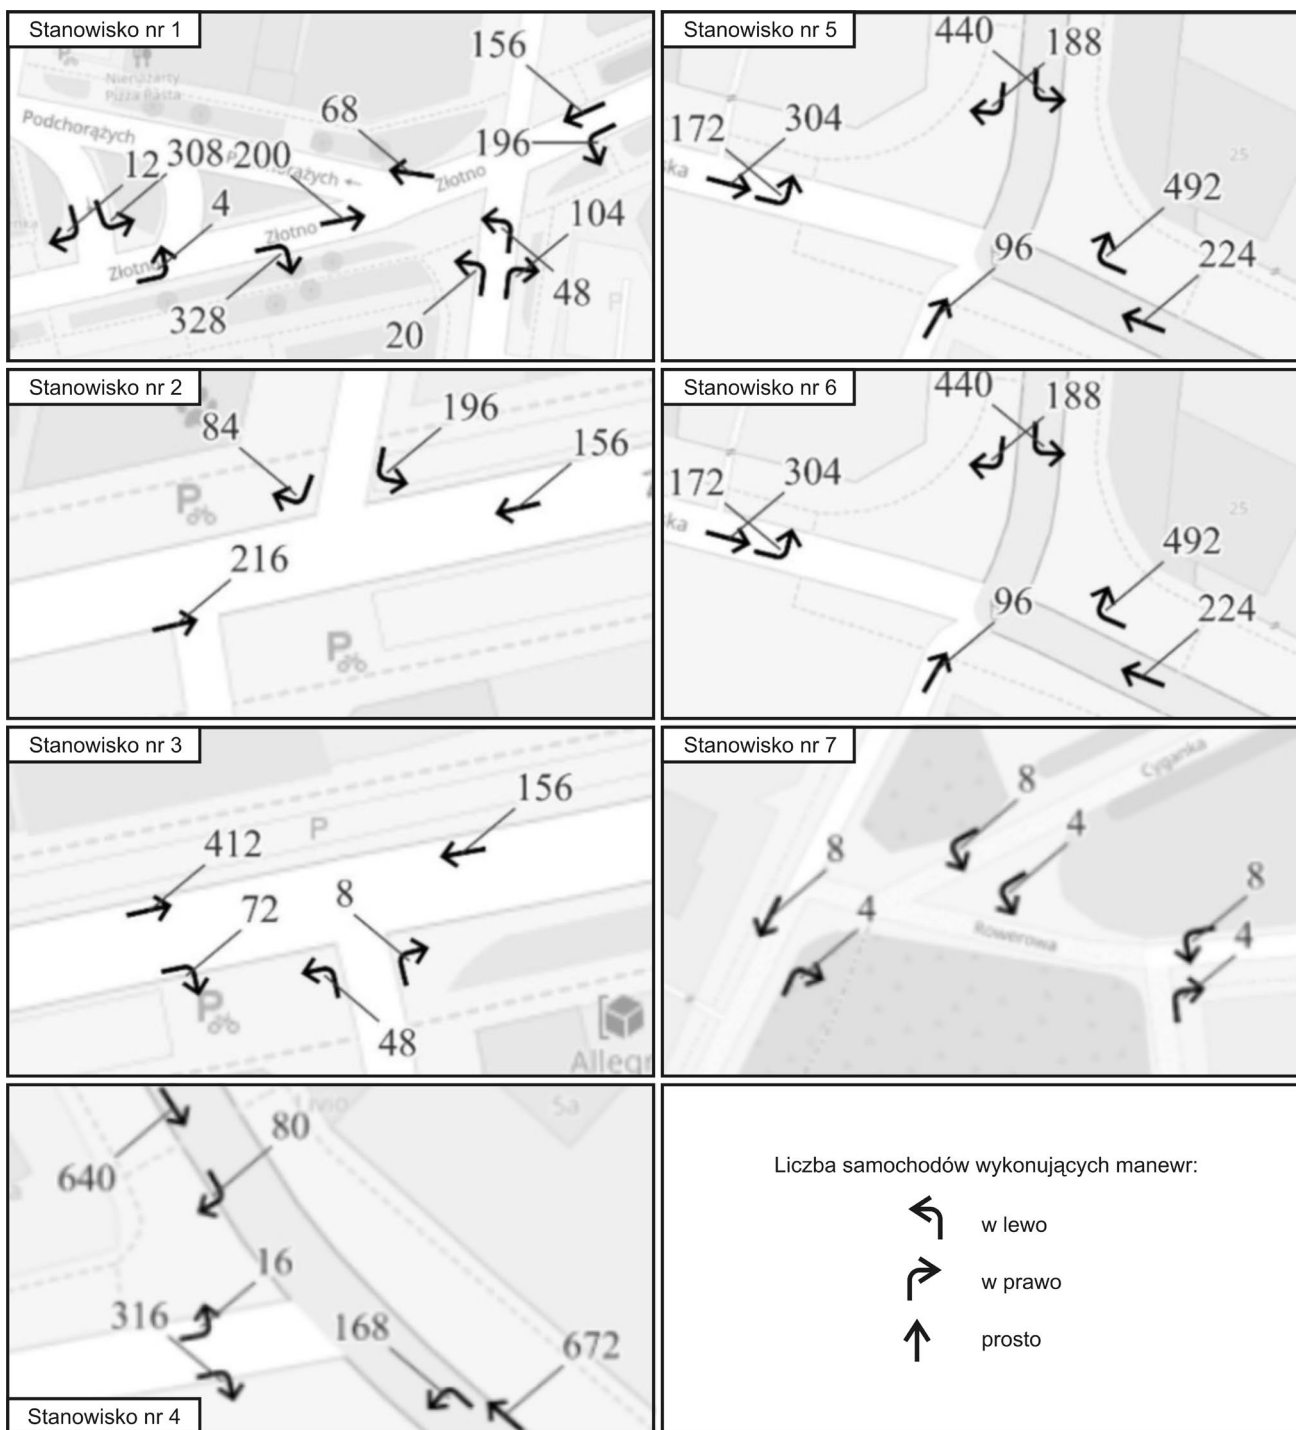
Źródło: opracowanie własne.

Pomiaru dokonano w dniach 17 listopada 2023 r. oraz 14 kwietnia 2025 r. w godzinach porannego szczytu komunikacyjnego między godz. 7.00 a 9.00 (Kowalski i Wiśniewski, 2017). Na każde skrzyżowanie poświęcono 15 minut (17 listopada 2023 r.) i 30 minut (14 kwietnia 2025 r.), a następnie znormalizowano wyniki tak, by otrzymać liczbę pojazdów na godzinę. Wyniki pomiarów przedstawiono na rysunku 5 (zob. s. 14). Wnioski wypływające z analizy ruchu drogowego na badanych skrzyżowaniach wskazują na wyraźne zróżnicowanie jego intensywności. Skrzyżowanie ulic Traktorowa–Rąbieńska–Szeregową (rysunek 4: stanowisko 5), jak również skrzyżowanie Rąbieńskiej i Złotno (rysunek 4: stanowisko 4) charakteryzują się największą ruchliwością. W odniesieniu do strategicznego (w kontekście obszaru *Studium*) skrzyżowania Złotno–Poniatowskiego–Podchorążych–Fizyliów (rysunek 4: stanowisko 1) zanotowano umiarkowany poziom ruchu. Na pozostałych skrzyżowaniach zaobserwowano zdecydowanie niższą aktywność komunikacji kołowej. Analiza ta sugeruje zróżnicowaną dynamikę ruchu w poszczególnych lokalizacjach.

W dalszej części badania na podstawie zgromadzonych danych wyznaczono wielkości potoków ruchu pomiędzy skrzyżowaniami i przedstawiono na rysunku 6 (zob. s. 15). Zakres przeprowadzonych pomiarów terenowych został zoptymalizowany pod kątem dostępnych zasobów finansowych i czasowych. W celu osiągnięcia wyższego poziomu precyzji i pewności statystycznej można byłoby wydłużyć czas badania, dodać kolejne pomiary dla innych dat (cechujących się np. różnymi warunkami pogodowymi) lub zwiększyć liczbę punktów pomiarowych, ale każdorazowo wymagałoby to zaangażowania większej grupy osób i wzrostu nakładów finansowych. Takie działania prowadziłyby do znacznego podniesienia kosztów ich przeprowadzenia, a w konsekwencji do ograniczenia możliwości wykorzystania tej metody w praktyce. Podsumowując, dążono do uzyskania danych, które pozwolą na uchwycenie ogólnych zależności charakteryzujących ruch drogowy na obszarze badania przy zastosowaniu optymalnego poziomu zaangażowania środków na ich pozyskanie.

Na podstawie zgromadzonych danych z pomiarów terenowych zostały utworzone tabele, w których przedstawiono informacje zawierające liczbę samochodów na najważniejszych ulicach wlotowych oraz wylotowych badanego obszaru. Liczbę pojazdów przedstawiono w tabeli 2 (zob. s. 15). Następnie dane te przetworzono za pomocą metody iteracyjnego dopasowania proporcjonalnego (ang. *iterative proportional fitting*) na macierz relacji źródło–cel i wyniki przedstawiono w tabeli 3 (zob. s. 16).

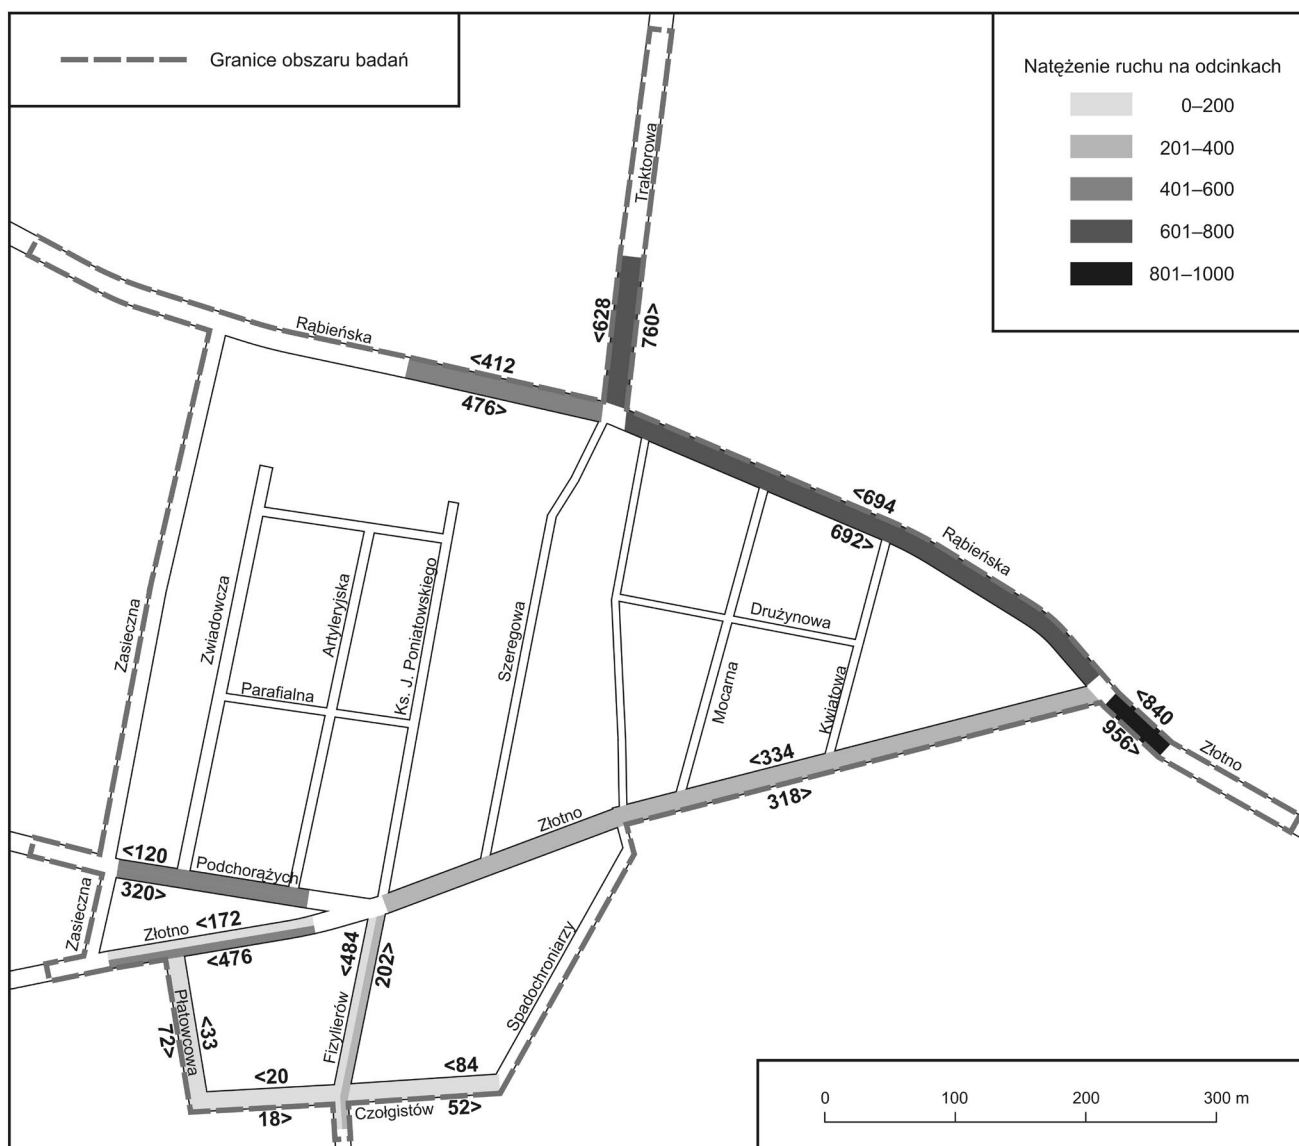
Uzyskano również dane z aplikacji TomTom, która wykorzystuje metodę wyznaczania średniej prędkości i czasu przejazdu na badanym odcinku sieci drogowej FCD z ponad 600 mln podłączonych globalnie urządzeń (TomTom, 2023). W ramach portalu MOVE istnieje



Rysunek 5. Schemat kierunków jazdy samochodów na badanym obszarze Złotna w podziale na stanowiska pomiarowe  
Źródło: opracowanie własne

możliwość analizy różnych parametrów ruchu drogowego, takich jak: natężenie ruchu, prędkość poruszania się pojazdów, pary O/D (z ang. *origin-destination pairs*) i wiele innych parametrów. Należy jednak podkreślić, że aplikacja nie daje możliwości podziału pojazdów na typy. W ramach tego badania zostało wykorzystane narzędzie O/D *analysis* dostarczające dane o przejazdach z punktu do punktu w zadanym okresie oraz statystyk ruchu (ang. *traffic stats*), przekazujące informacje dotyczące prędkości na wybranych odcinkach dróg.

Narzędzie pozwoliło na analizę 28 tys. przejazdów na 594 km odcinków (suma odcinków na obszarze badania oraz w buforze o promieniu 10 km). Podczas prowadzenia badań w 2023 r. aplikacja pozwalała na analizę danych z października 2022 r., natomiast w 2025 r. udostępniane były statystyki z sierpnia 2024 r. Analizie poddano tylko robocze dni tygodnia podczas szczytu komunikacyjnego – w godzinach 7.00–9.00 i 14.00–18.00. Na podstawie zgromadzonych danych z aplikacji TomTom utworzono macierz relacji źródło-cel zawierającą



Rysunek 6. Natężenie ruchu samochodowego i główne potoki ruchu na wybranych ulicach osiedla Złotno 17 listopada 2023 r.  
Źródło: opracowanie własne

liczbę pojazdów przemieszczających się ze źródeł do celów w ciągu jednej godziny. Wyniki przedstawiono w tabeli 4 (zob. s. 16).

Tabela 2. Liczba pojazdów na wlotach i wylotach ulic badanego fragmentu osiedla Złotno 17 listopada 2023 r.

| Wlot (ulica)          | Liczba pojazdów na godzinę | Wylot (ulica)         | Liczba pojazdów na godzinę |
|-----------------------|----------------------------|-----------------------|----------------------------|
| 1. Fizylierów         | 184                        | 1. Fizylierów         | 518                        |
| 2. Złotno             | 448                        | 2. Złotno             | 180                        |
| 3. Podchorążych       | 320                        | 3. Podchorążych       | 120                        |
| 4. Rąbieńska (zachód) | 476                        | 4. Rąbieńska (zachód) | 412                        |
| 5. Traktorowa         | 628                        | 5. Traktorowa         | 760                        |
| 6. Rąbieńska (wschód) | 840                        | 6. Rąbieńska (wschód) | 956                        |

Źródło: opracowanie własne.

## 2.5. BUDOWA MODELU SIECI

Geometrię sieci dla badanego obszaru osiedla Złotno odwzorowano w programie PTV VISSIM, opierając się na danych pochodzących z ortofotomapy podkładowej, danych GIS dostarczających informacji o szerokości jezdni, trójwymiarowego modelu Google Earth oraz dokumentacji zdjęciowej sporządzonej podczas wizji lokalnej. Zamodelowana sieć uliczna obejmuje łączną długość 6,3 km i 25 skrzyżowań, w tym jedno skrzyżowanie sterowane sygnalizacją stałoczasową (Rąbieńska-Traktorowa), której program został odwzorowany na podstawie zapisu wideo. Na etapie budowy modelu szczególną uwagę poświęcono precyzyjnemu odwzorowaniu geometrii sieci, dostosowaniu dopuszczalnych prędkości, lokalizacji znaków drogowych i przejść dla pieszych, ustaleniu pierwszeństwa przejazdu na skrzyżowaniach i ustawieniu sygnalizacji stałoczasowej

Tabela 3. Macierz relacji źródło–cel wygenerowana na podstawie pomiarów terenowych

| Źródło–cel (ulica) | Fizylierów | Złotno | Podchorążych | Rąbieńska (zachód) | Traktorowa | Rąbieńska (wschód) |
|--------------------|------------|--------|--------------|--------------------|------------|--------------------|
| Fizylierów         | x          | 34,36  | 71,46        | 7,31               | 57,63      | 13,23              |
| Złotno             | 161,23     | x      | 4,17         | 2,15               | 101,80     | 178,66             |
| Podchorążych       | 251,78     | 17,10  | x            | 0,51               | 9,17       | 41,44              |
| Rąbieńska (zachód) | 4,77       | 3,68   | 2,00         | x                  | 124,61     | 340,93             |
| Traktorowa         | 57,79      | 52,61  | 20,63        | 122,87             | x          | 374,11             |
| Rąbieńska (wschód) | 13,22      | 70,31  | 22,32        | 275,75             | 458,40     | x                  |

Źródło: opracowanie własne.

Tabela 4. Macierz relacji źródło–cel wygenerowana z aplikacji TomTom MOVE

| Źródło–cel (ulica) | Fizylierów | Złotno | Podchorążych | Rąbieńska (zachód) | Traktorowa | Rąbieńska (wschód) |
|--------------------|------------|--------|--------------|--------------------|------------|--------------------|
| Fizylierów         | x          | 32,17  | 74,83        | 2,33               | 18,17      | 9,00               |
| Złotno             | 40,67      | x      | 11,67        | 1,83               | 85,83      | 325,00             |
| Podchorążych       | 97,17      | 65,50  | x            | 0,67               | 11,83      | 115,33             |
| Rąbieńska (zachód) | 1,00       | 7,67   | 4,67         | x                  | 87,33      | 515,50             |
| Traktorowa         | 18,17      | 164,17 | 72,00        | 130,83             | x          | 848,17             |
| Rąbieńska (wschód) | 6,17       | 325,67 | 115,67       | 435,83             | 715,00     | x                  |

Źródło: TomTom (2023).

(Gaca i in., 2014). Badanie przeprowadzono z wykorzystaniem modułu dynamicznego przypisywania – DA (z ang. *dynamic assignment*) oprogramowania VISSIM, który pozwala na wyszukiwanie ścieżek przez kierowców w sposób niezależny od użytkownika. System działa w sposób iteracyjny, tzn. kierowcy „uczą się” na poprzednich symulacjach i ich zachowania bazują na wynikach z poprzednich iteracji symulacji. Każdy kierowca podejmuje decyzje na każdym skrzyżowaniu niezależnie, wyszukując najlepszą trasę dojazdu do danego punktu. Parametry brane pod uwagę to czas dojazdu, trasa przejazdu, koszt przejazdu, a także dodatkowa opłata, która może być zdefiniowana przez użytkownika.

## 2.6. KALIBRACJA MODELU

Kalibracja modelu mikrosymulacyjnego polega na dostosowaniu jego parametrów wewnętrznych (np. parametrów ruchu pojazdów) w taki sposób, aby symulowane zachowania i wyniki były jak najbardziej zbliżone do danych z rzeczywistości. Z kolei walidacja to proces weryfikacji, czy tak skalibrowany model jest w stanie pokazać przyszłe działania systemu w nowych, nieznanach dotąd warunkach. W literaturze przedmiotu (Hellinga, 1998; Lownes i Machemehl, 2006; Park i Schneeberger, 2003) podkreśla się, że kalibracja i walidacja nie są jednorazowymi krokami, lecz procesami iteracyjnymi, które mogą wymagać wielokrotnych

powtórzeń, dopóki nie osiągnie się akceptowalnej spójności pomiędzy symulacją a rzeczywistością.

W badaniach nad kalibracją modeli mikrosymulacyjnych można wyróżnić dwa podejścia: podejście manualne wykorzystujące próby i błędy (Park i Schneeberger, 2003) oraz podejście automatyczne, bazujące na algorytmach optymalizacji (Karimi i in., 2019). Coraz częściej badacze wskazują na potrzebę wykorzystania automatycznych metod optymalizacji, np. algorytmów genetycznych, w celu przyspieszenia procesu kalibracji i osiągnięcia bardziej optymalnych wyników, szczególnie w przypadku złożonych sieci transportowych (Park i Qi, 2005). W ostatnich latach badacze zaczynają stosować także metody z zakresu sztucznej inteligencji, takie jak sieci neuronowe (Otković i in., 2013; Otković i in., 2020), które pozwalają na odwzorowanie nieliniowych zależności występujących w ruchu drogowym.

Należy podkreślić, że sama kalibracja i walidacja są ściśle powiązane z procesem zbierania danych. Przykładowo, w przypadku obszarów o dużym udziale ruchu pieszych parametry odpowiedzialne za ruch pieszych w modelach mikrosymulacyjnych powinny być również przedmiotem szczegółowej kalibracji i walidacji (Ishaque i Noland, 2009). Jest to szczególnie ważne w kontekście dynamicznych zmian w ruchu i specyfiki zachowań kierowców w danym obszarze, co podkreślają badacze (Manjunatha i in., 2013).

W celu dopasowania parametrów modelu do warunków rzeczywistych przeprowadzono kalibrację,

a w ramach wykorzystania metody projektowania eksperymentów posłużono się tablicą ortogonalną Taguchi L9. Na podstawie literatury (Al-Msari i in., 2024; Bandi i George, 2020; El Esawey i Sayed, 2011; Park i Won, 2006a) sklasyfikowano cztery najistotniejsze parametry, które testowano na trzech poziomach w celu uzyskania optymalnych rezultatów i skalibrowania modelu. Te parametry to:

- średni odstęp w zatrzymaniu (ang. *average standstill distance*) w metrach, zakres 1–2 m;
- dodatkowa odległość bezpieczeństwa (ang. *additive part of desired safety distance*) w metrach, zakres 1–2 m;
- mnożnik odstępów bezpieczeństwa (ang. *multiplicative part of desired safety distance*), zakres 1–3;
- współczynnik redukcji odległości bezpieczeństwa (ang. *safety distance reduction factor*), zakres 0,4–0,6.

Przy kalibrowaniu modelu wprowadzano także obszary ograniczonej prędkości i dopasowywano decyzje o prędkości pożądanej. W przypadku, gdy natężenie na odcinkach było zbyt duże i wskaźnik GEH był większy od 10, wprowadzono opłaty dodatkowe w wysokości od 10 do 40 (El Esawey i Sayed, 2011, s. 69). W procesie DA przeprowadzono 50 symulacji dla każdego rozpatrywanego wariantu, tak aby uzyskać jak największą zgodność modelu z rzeczywistością oraz wystarczającą liczbę danych (Florida Department of Transportation, 2014). Analizy statystyczne prowadzono na wynikach uśrednionych ze wszystkich symulacji dla każdego wariantu.

## 2.7. WALIDACJA MODELU

Celem walidacji jest sprawdzenie parametrów modelu na danych, na których nie był trenowany. Walidacja to niezależny proces oceny, mający na celu sprawdzenie, czy skalibrowany model mikrosymulacyjny realistycznie i z zadowalającą dokładnością odwzorowuje rzeczywiste warunki ruchu w systemie transportowym, który ma symulować (Park i Schneeberger, 2003). Walidacja nie polega na dalszym dostrajaniu parametrów modelu; jest to test weryfikujący, czy model z parametrami ustalonymi podczas kalibracji potrafi pokazać przyszłe działanie systemu w warunkach innych niż te, które były jej podstawą. Kluczowym elementem walidacji jest wykorzystanie niezależnego zestawu danych (Park i Won, 2006b). Zestaw ten musi być odrębny od danych użytych do kalibracji – mogą to być informacje zebrane w innym okresie (inny dzień, inna pora dnia) lub z innych lokalizacji w sieci, jeśli kalibracja dotyczyła tylko jej części. Dane walidacyjne powinny obejmować te same MoE, względem których prowadzono kalibrację. Należy zaznaczyć, że praktyka modelowania wskazuje, że w przypadku złożonych, wieloskalowych sieci miejskich pełne spełnienie wszystkich założonych kryteriów walidacyjnych bywa wyzwaniem. Badanie przeprowadzone na przykładzie dużej sieci miejskiej w USA (So i in., 2016) ukazało, że jedynie część z przyjętych MoE

była w stanie osiągnąć zakładane kryteria walidacji. Jako potencjalne przyczyny takiego stanu rzeczy autorzy wskazywali m.in. na większą wrażliwość danych zbieranych przez detektory w porównaniu do informacji dotyczących czasów przejazdu oraz na wpływ zmian sezonowych w charakterystyce ruchu drogowego.

## 3. WYNIKI BADAŃ

Kalibracja i walidacja modelu VISSIM dla stanu istniejącego została przeprowadzona w celu porównania dwóch odmiennych źródeł danych referencyjnych: danych z aplikacji TomTom MOVE oraz danych z pomiarów terenowych. Zastosowano przy tym następującą procedurę:

1. Przeprowadzono dwie równoległe ścieżki kalibracyjne. W pierwszej parametry modelu dostrajano, porównując wyniki symulacji dla natężenia ruchu oraz prędkości pojazdów z danymi TomTom MOVE. W drugiej przeprowadzono analogiczny proces z wykorzystaniem danych terenowych.
2. Analizowano uzyskane zestawy parametrów. W obu procedurach kalibracyjnych dążono do osiągnięcia optymalnych zestawów parametrów behawioralnych modelu. Okazało się, że wartości wyselekcjonowanych parametrów behawioralnych otrzymane w obu ścieżkach kalibracyjnych były takie same. Sugeruje to, że w badanym przypadku, mimo różnic w naturze danych wejściowych, proces kalibracji prowadził do podobnego opisu zachowań kierowców.
3. Porównano wskaźniki dopasowania. Następnie oceniono jakość dopasowania każdego z modeli do swoich danych referencyjnych. W tym celu obliczono wartości wskaźników GEH i SQV dla natężeń ruchu oraz RMSE i CC dla prędkości pojazdów. Wyniki tego porównania, zestawione w tabeli 5 (zob. s. 19), pokazały marginalne różnice w osiągniętych poziomach dopasowania. Model kalibrowany na danych TomTom osiągnął zbliżone wskaźniki GEH i RMSE w stosunku do modelu kalibrowanego na danych terenowych. Nieznaczne różnice pomiędzy wartościami wskaźników mogą wynikać bezpośrednio z charakterystyki i potencjalnie różnej jakości porównywanych źródeł danych.

Uzyskane parametry kalibracji prezentują się w następujący sposób:

- średni odstęp w zatrzymaniu: 1,5 m;
- dodatkowa odległość bezpieczeństwa: 1 m;
- mnożnik odstępów bezpieczeństwa: 1;
- współczynnik redukcji odległości bezpieczeństwa: 0,4.

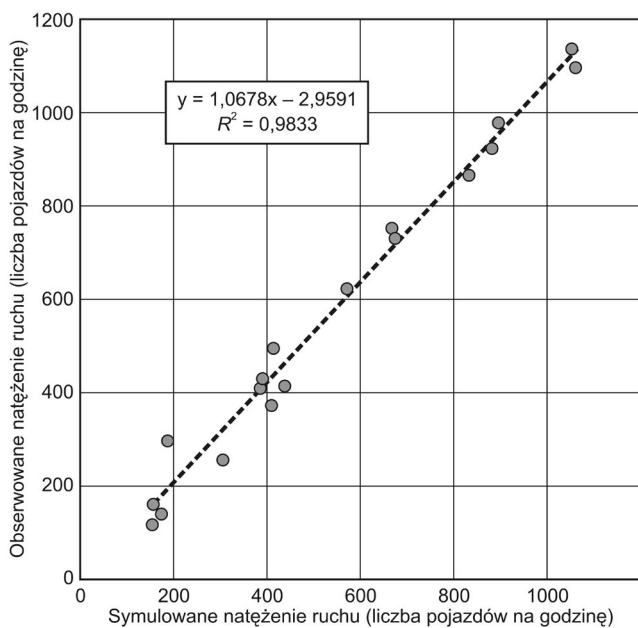
Wyniki kalibracji modelu dla różnych typów danych przedstawiono na rysunkach 7–10 (zob. s. 18) oraz w tabeli 5. Wyniki walidacji przedstawiono w tabeli 6 (zob. s. 19).

Na rysunkach 7 i 8 zaprezentowano różnice pomiędzy wartościami zmierzonymi a symulowanymi. Dane

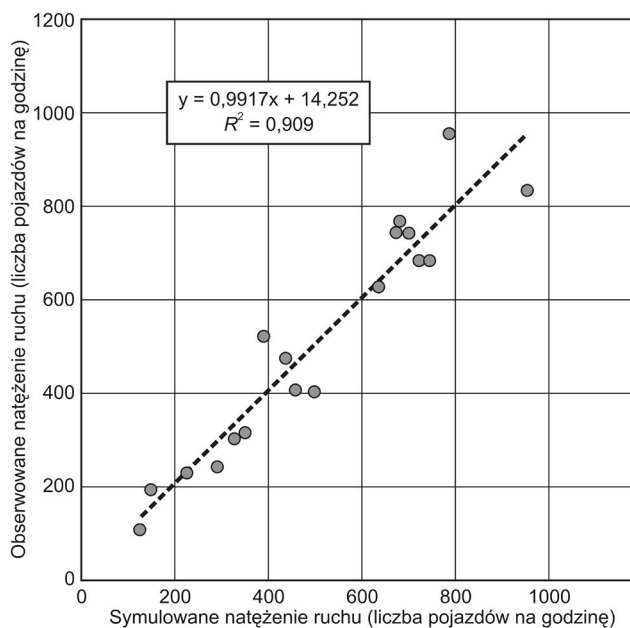
z aplikacji TomTom mają mniejszy rozrzut oraz wyższy współczynnik determinacji  $R^2$  w porównaniu do danych terenowych. Analogiczna sytuacja występuje na rysunkach 9 i 10, na których przedstawiono prędkości zmierzone oraz symulowane.

Z tabeli 5 wynika, że oba modele spełniają założenia kalibracyjne. Dane TomTom pozwoliły na uzyskanie niższego wskaźnika GEH i RMSE oraz wyższego wskaźnika SQV i współczynnika korelacji w porównaniu do danych zbieranych w terenie. Tak skalibrowany model poddano walidacji.

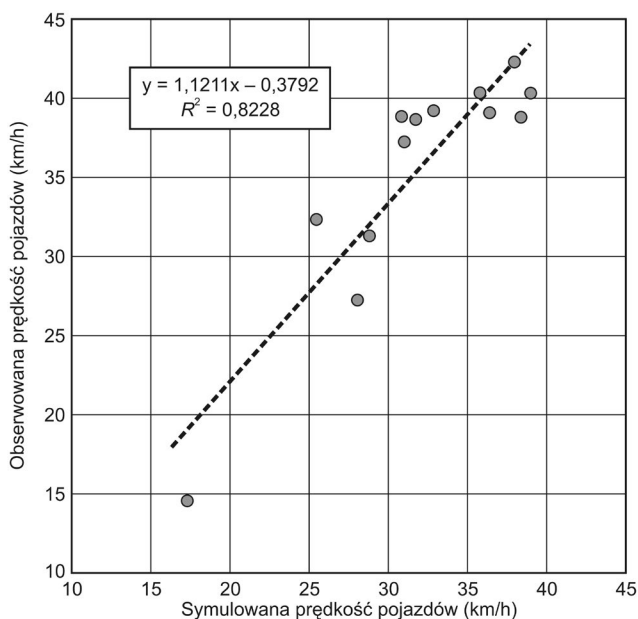
Do walidacji dwóch modeli wykorzystano dane nie używane podczas kalibracji. Wskaźniki dokładności symulacji mieściły się w założonych przedziałach. Jak przedstawiono w tabeli 6, osiągnięto niższy wskaźnik SQV i współczynnik korelacji dla danych TomTom w porównaniu do etapu kalibracji. Wartości analogicznych wskaźników dla danych terenowych nie zmieniły się znacząco. Zanotowano wyższe wskaźniki GEH i RMSE. Biorąc pod uwagę skalę sieci oraz nakład czasu poświęcony na przygotowanie modelu, uznano go za skalibrowany i zwalidowany.



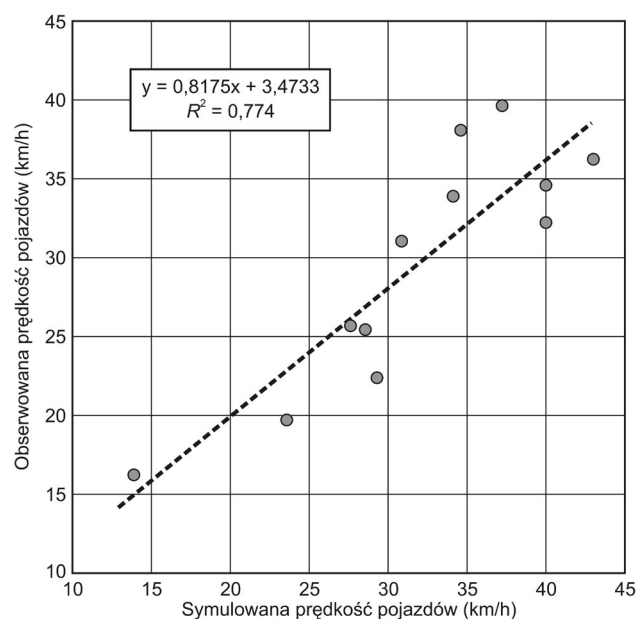
Rysunek 7. Porównanie różnic między natężeniem ruchu w aplikacji TomTom a symulowanym natężeniem  
Źródło: opracowanie własne



Rysunek 8. Porównanie różnic między zmierzonym rzeczywistym natężeniem ruchu a symulowanym natężeniem  
Źródło: opracowanie własne



Rysunek 9. Porównanie różnic między prędkością jazdy w aplikacji TomTom a symulowaną prędkością jazdy  
Źródło: opracowanie własne



Rysunek 10. Porównanie różnic między zmierzoną rzeczywistą prędkością jazdy a symulowaną prędkością jazdy  
Źródło: opracowanie własne

Tabela 5. Zestawienie wartości miar efektywności (MoE) w zależności od metody zbierania danych w fazie kalibracji

| Metoda zbierania danych | Wskaźnik GEH dla natężenia ruchu | Skalowalny wskaźnik jakości SQV dla natężenia ruchu | Pierwiastek błędu średniokwadratowego RMSE dla prędkości pojazdów (%) | Współczynnik korelacji dla prędkości pojazdów |
|-------------------------|----------------------------------|---|---|---|
| Dane TomTom             | 2,30                             | 0,935   | 12,395  | 0,907   |
| Dane terenowe           | 2,54                             | 0,929   | 14,900  | 0,880   |

Źródło: opracowanie własne.

Tabela 6. Zestawienie wartości miar efektywności (MoE) w zależności od metody zbierania danych w fazie walidacji

| Metoda zbierania danych | Wskaźnik GEH dla natężenia ruchu | Skalowalny wskaźnik jakości SQV dla natężenia ruchu | Pierwiastek błędu średniokwadratowego RMSE dla prędkości pojazdów (%) | Współczynnik korelacji dla prędkości pojazdów |
|-------------------------|----------------------------------|---|---|---|
| Dane TomTom             | 4,34                             | 0,889   | 14,559  | 0,849   |
| Dane terenowe           | 2,89                             | 0,919   | 14,709  | 0,912   |

Źródło: opracowanie własne.

#### 4. DYSKUSJA

Przeprowadzone analizy miały na celu ocenę i porównanie dwóch odmiennych metod zbierania danych na potrzeby mikroskopowej symulacji ruchu – tradycyjnych pomiarów terenowych oraz danych FCD dostarczanych przez platformę komercyjną TomTom, a także określenie ich implikacji dla procesu planowania przestrzennego. Choć uzyskane w ramach kalibracji i walidacji wartości wskaźników efektywności (np. GEH, RMSE) nie wykazały drastycznych różnic między modelami opartymi na obu źródłach danych, to same metody uzyskiwania danych charakteryzują się fundamentalnymi odmiennosiami, które wpływają na ich praktyczną użyteczność i wiarygodność.

Pomiary terenowe, w formie obserwacji bezpośrednich lub analizy nagrań wideo, cechują się względną prostotą koncepcyjną i implementacyjną. Pozwalają na bezpośrednie zliczanie i klasyfikację pojazdów oraz obserwację specyficznych zachowań na skrzyżowaniach czy odcinkach. Jednakże doświadczenia zebrane

podczas realizacji niniejszego badania potwierdzają istotne ograniczenia praktyczne tej metody:

- wysokie wymagania zasobowe – rzetelne badanie obejmujące większą liczbę skrzyżowań lub dłuższe okresy pomiarowe wymaga zaangażowania znacznych zasobów ludzkich;
- czasochłonność – proces obejmuje nie tylko wielogodzinne pomiary w terenie, które często są rozłożone na kilka dni, ale również pracochłonną analizę i przetwarzanie danych;
- ograniczenia logistyczne – konieczność fizycznej obecności w miejscu pomiaru oraz zapewnienia odpowiednich punktów obserwacyjnych na odpowiedniej wysokości, z dobrą widocznością oraz bezpiecznych dla obserwatorów może stanowić wyzwanie;
- ograniczenia geograficzne – metoda ta jest niemożliwa do zastosowania przy badaniu obszarów odległych geograficznie.

Porównując pomiary terenowe z metodą wykorzystania danych FCD, dostarczanych przez platformy, takie jak TomTom MOVE, zauważa się odmienny zestaw zalet i wad. Do zalet zaliczyć można:

- efektywność zasobową – znaczącą redukcję zapotrzebowania na zasoby ludzkie na etapie zbierania i przetwarzania danych;
- szeroki zasięg – możliwość analizy odległych lokalizacji oraz rozległych obszarów sieciowych bez konieczności fizycznej obecności;
- pokrycie czasowe – dostęp do danych historycznych dla długich okresów i różnych pór doby/dni tygodnia;
- potencjalnie wysoką reprezentatywność dzięki dużej liczbie użytkowników – platforma opiera się na danych lokalizacyjnych od licznej grupy użytkowników, pasywnie dostarczających informacje, co może prowadzić do lepszego odzwierciedlenia ogólnych wzorców ruchu.

Z kolei wadami są:

- niepewność i nieprzejrzystość danych – metodologia zbierania i przetwarzania danych przez dostawców komercyjnych często stanowi tajemnicę przedsiębiorstwa, co utrudnia pełną ocenę jakości, wiarygodności i potencjalnych błędów w nich zawartych;
- dostępność i koszty – dostęp do szczegółowych danych historycznych lub danych czasu rzeczywistego za pośrednictwem platform komercyjnych jest zazwyczaj płatny i ograniczony licencyjnie;
- poziom agregacji – dane FCD są często zagregowane do określonych segmentów, co może ograniczać wgląd w lokalne, mikroskopowe uwarunkowania ruchu, specyficzne zachowania kierowców, niestandardowe przyczyny kongestii (np. nagłe zmiany pasa, krótkotrwałe blokady itp.).

Uzyskane w niniejszym badaniu wartości wskaźnika GEH dla modeli skalibrowanych na danych TomTom i terenowych, wynoszące odpowiednio: 2,30 i 2,54, są

porównywalne z rezultatami raportowanymi przez Hafra i in. (2023). W ich badaniu, obejmującym dwujezdniową, dwupasową drogę w gęstej zabudowie miejskiej Makassar w Indonezji i wykorzystującym pomiary manualne oraz rejestrację wideo, wartości GEH mieściły się w przedziale od 2,03 do 3,96. Podobnie osiągnięte współczynniki korelacji dla prędkości (odpowiednio: 0,91 i 0,88) wykazują zbliżony poziom dopasowania do badań prowadzonych dla 5-kilometrowego odcinka miejskiej drogi szybkiego ruchu w Orlando na Florydzie, gdzie przy zastosowaniu pomiarów manualnych, wideo oraz danych FCD uzyskano współczynnik korelacji równy 0,96 (Rahman i in., 2019).

Należy jednak podkreślić, że bezpośrednie porównywanie wyników różnych badań jest utrudnione ze względu na znaczące różnicowanie warunków lokalnych. Oprócz wskaźników efektywności należy brać pod uwagę m.in.: charakterystykę analizowanego obszaru, zastosowaną metodę zbierania danych oraz sposób kalibracji. Można zauważyć, że wraz ze wzrostem zaawansowania technik kalibracji rośnie precyzja symulacji. Bandi i George (2020), wykorzystując jedynie materiał wideo i zaawansowaną analizę czułości, osiągnęli wskaźnik GEH na poziomie 1,51.

Kluczowe dla wiarygodności symulacji są również parametry behawioralne kierowców, które wykazują silną zależność od lokalizacji badania. W niniejszym studium średni odstęp w zatrzymaniu wyniósł 1,5 m. Jest to wartość niższa niż 2 m, zanotowana w hrabstwie Broward na Florydzie dla modelu obejmującego 160 skrzyżowań ulic obszaru zabudowy jednorodzinnej przecinanej drogami szybkiego ruchu (So i in., 2016). Z kolei obserwacje badaczy z Azji wskazują na tendencję do jeszcze mniejszych wartości tego parametru: od 0,4 m w gęstej organicznej tkance miejskiej Mangalore w Indiach (model 423 odcinków na 3 km<sup>2</sup>) (Bandi i George, 2020) do 1,1 m na obrzeżach Bangalore w strefie hubu IT (model 9 skrzyżowań na 30 ha) (Mohan i in., 2021).

Podobne zróżnicowanie geograficzne wykazują również inne kluczowe parametry modelu behawioralnego. Wpływ na zachowanie kierowców ma bowiem wiele czynników, takich jak: geometria trasy, jej typ (autostrada, ulica miejska), struktura rodzajowa pojazdów oraz ich wymiary. Z powyższego wynika, że jednym z celów przy budowie modelu mikrosymulacyjnego jest zawsze możliwie wierne odwzorowanie specyficznych warunków lokalnych, co nieuchronnie prowadzi do wniosku o konieczności każdorazowego przeprowadzania starannej lokalnej kalibracji parametrów behawioralnych modelu. Wybór adekwatnych wartości tych parametrów, odzwierciedlających lokalną kulturę jazdy i charakterystykę ruchu, jest niezbędny do uzyskania wiarygodnych wyników symulacji. Odpowiedni wybór wartości tych parametrów jest związany z rzetelnym zebraniem danych z obszaru opracowania metodą dopasowaną do występujących lokalnie warunków.

Analiza porównawcza zastosowanych metod zbierania danych prowadzi do kilku istotnych wniosków. Wybór odpowiedniej metody pozyskiwania danych referencyjnych na potrzeby mikrosymulacji ruchu jest uwarunkowany specyfiką analizowanego obszaru i dostępnymi zasobami. W niniejszym badaniu nie zaobserwowano większych różnic w jakości modeli skalibrowanych na podstawie obu typów danych pod względem wskaźników efektywności. Sugeruje to, że kluczowym kryterium wyboru metody staje się nie tyle potencjalna wiarygodność samych wyników, co raczej praktyczne aspekty jej implementacji, takie jak: możliwość zastosowania w danej sytuacji, łatwość adaptacji oraz uwarunkowania logistyczne i kosztowe.

Przedstawiona charakterystyka obu metod wskazuje, że w zależności od stopnia skomplikowania analizowanej sieci drogowej oraz jej typu, bardziej wskazane może być zastosowanie konkretnej techniki pomiarowej lub, jak sugeruje wielu badaczy, integracja danych z wielu źródeł (Auberlet i in., 2014; So i in., 2016, s. 17). Czynniki determinujące wybór to przede wszystkim dostępność danych oraz całkowity koszt ich uzyskania i przetworzenia (Mohan i in., 2021, s. 16). W analizowanym studium przypadku, ze względu na brak istniejącej infrastruktury pomiarowej w postaci pętli indukcyjnych, rozważano jedynie pomiary wideo i dane FCD. Chociaż rejestracja wideo może wydawać się metodą prostą, to przy większej skali badania koszty związane z zaangażowaniem personelu i czasochłonną analizą materiału mogą przewyższyć wydatki związane z dostępem do komercyjnych platform agregujących dane FCD. W jednym z badań zaznaczono, że do zbierania danych zaangażowano ok. 200 osób (Mosseri i in., 2004). Badacze zwracają również uwagę na zrównoważenie między dokładnością symulacji a czasochłonnością procesu zbierania danych i kalibracji, szczególnie przy większych sieciach, gdzie istnieje ryzyko przeinwestowania w ilość czasu na dostrajanie parametrów. W niektórych przypadkach walidacja modelu może być niemożliwa w dostępnym czasie, na co ma wpływ jakość danych wejściowych (So i in., 2016, s. 15).

W niniejszym badaniu, mimo odmiennej natury, oba analizowane źródła danych okazały się wysoce użyteczne i pozwoliły na uzyskanie akceptowalnych progów kalibracyjnych, co świadczy o ich potencjalnym praktycznym zastosowaniu w modelowaniu ruchu do potrzeb planowania przestrzennego. Niemniej jednak wybór konkretnej metody zbierania danych wiąże się z istotnym kompromisem. Pomiary terenowe oferują bezpośrednią obserwację i potencjalnie większy wgląd w lokalne, mikroskopowe uwarunkowania ruchu, jednak ich implementacja jest często ograniczona czasochłonnością i zasobochłonnością. Z kolei dane FCD charakteryzują się szerokim zasięgiem przestrzennym i czasowym oraz efektywnością zasobową, lecz mogą cechować się mniejszą przejrzystością metodologii pozyskiwania i agregacji

oraz ograniczonym wglądem w specyficzne, lokalne zjawiska ruchowe. Ostateczna decyzja dotycząca doboru metody lub ich kombinacji powinna zatem uwzględniać specyfikę analizowanego obszaru, cele modelowania oraz dostępne zasoby. Świadomy wybór w tym zakresie, oparty na zidentyfikowanych w niniejszej pracy charakterystykach obu podejść, jest kluczowy do skutecznej praktyki wspierania planowania przestrzennego w analizach transportowych.

## 5. PODSUMOWANIE

Niniejszy artykuł prezentuje studium przypadku dotyczące wpływu wyboru metody zbierania danych na proces kalibracji mikrosymulacji ruchu przeprowadzonej na przykładzie wyselekcjonowanego fragmentu osiedla Złotno w Łodzi. W badaniu porównano dwie metody pozyskiwania danych: tradycyjne pomiary terenowe natężenia ruchu oraz podejście oparte na danych z aplikacji TomTom MOVE. Celem badania było określenie użyteczności i wiarygodności danych z dwóch różnych źródeł w kontekście modelowania ruchu na potrzeby planowania przestrzennego.

Wykorzystując moduł *dynamic assignment* programu VISSIM, przeprowadzono analizę porównawczą dwóch źródeł danych dla modelu mikrosymulacyjnego. Skalibrowaną symulację przy użyciu obu metod zbierania danych poddano ocenie z wykorzystaniem wskaźników RMSE, CC, GEH oraz SQV. Rezultaty wykazały brak różnic w kwestii wiarygodności symulacji, jednak pozwoliły dostrzec zróżnicowany zestaw zalet oraz wad, które wskazują na to, że wybór metody zbierania danych odgrywa kluczową rolę i musi być dopasowany do lokalnie występujących warunków.

Przeprowadzone badania ujawniają znaczenie wyboru odpowiedniej metody zbierania danych w procesie mikrosymulacji ruchu. Nowoczesne technologie, takie jak TomTom MOVE, dostarczają cennych informacji uzupełniających tradycyjne metody pomiarowe i przyczyniają się do ułatwienia procesu tworzenia modeli, które są niezbędne do podejmowania świadomych i trafnych decyzji w zakresie planowania przestrzennego. Precyzyjne symulacje pozwalają na weryfikację różnych scenariuszy rozwoju infrastruktury, identyfikację potencjalnych problemów i optymalizację rozwiązań transportowych. W rezultacie badania takie mogą mieć istotny wpływ na kształtowanie bardziej przyjaznych, funkcjonalnych i bezpiecznych przestrzeni miejskich, w których priorytetem jest efektywność, zrównoważony rozwój oraz wysoka jakość życia mieszkańców. Lepsze zrozumienie dynamiki ruchu drogowego dzięki zaawansowanym narzędziom analitycznym otwiera drogę do organizowania miast, które są nie tylko lepiej skomunikowane, ale także bardziej odporne na wyzwania przyszłości.

## BIBLIOGRAFIA

- Abdeen, M.A.R., Farrag, S., Benaida, M., Sheltami, T., El-Hansali, Y. (2023). VISSIM calibration and validation of urban traffic: A case study Al-Madinah City. *Personal and Ubiquitous Computing*, 27(5), 1747–1756. <https://doi.org/10.1007/s00779-023-01738-9>
- Al-Msari, H., Koting, S., Ahmed, A.N., El-shafie, A. (2024). Review of driving-behaviour simulation: VISSIM and artificial intelligence approach. *Heliyon*, 10(4), artykuł e25936. <https://doi.org/10.1016/j.heliyon.2024.e25936>
- Auberlet, J.-M., Bhaskar, A., Ciuffo, B., Farah, H., Hoogendoorn, R., Leonhardt, A. (2014). Data collection techniques. W: W. Daamen, C. Buisson i S.P. Hoogendoorn (red.), *Traffic simulation and data: Validation methods and applications* (s. 5–32). CRC Press; Taylor & Francis Group.
- Bandi, M.M., George, V. (2020). Calibration of vehicle and driver characteristics in VISSIM and ANN-based sensitivity analysis. *International Journal of Microsimulation*, 13(2), 79–101. <https://doi.org/10.34196/ijm.00219>
- Ciesielski, M. (1986). *Zeszyty Naukowe Akademii Ekonomicznej w Poznaniu. Seria II Prace Doktorskie i Habilitacyjne. Z. 87: Koszty kongestii transportowej w miastach*. Wydawnictwo Akademii Ekonomicznej w Poznaniu. <https://www.wbc.poznan.pl/Content/82842/PDF/Ciesielski%20Marek%20-%20Koszty%20kongestii%20transportowej%20w%20miastach.pdf>
- Davis, R., Duany, A., Plater-Zyberk, E. (2002). *The lexicon of the new urbanism*. Duany Plater-Zyberk & Co.
- Del Serrone, G., Cantisani, G., Peluso, P. (2023). Blending of floating car data and point-based sensor data to deduce operating speeds under different traffic flow conditions. *European Transport / Transporti Europei*, 91, artykuł 5. <https://doi.org/10.48295/ET.2023.91.5>
- Domińczak, M. (2020). *Nowa Urbanistyka: Metodyka i zasady projektowania według SmartCode*. Wydawnictwo Politechniki Łódzkiej. <https://doi.org/10.34658/9788366287655>
- Dybiczy, T. (2009). Modelowanie i symulacje ruchu, rys historyczny i aktualnie stosowane oprogramowanie. *Zeszyty Naukowo-Techniczne Stowarzyszenia Inżynierów i Techników Komunikacji Rzeczypospolitej Polskiej. Oddział w Krakowie. Seria: Materiały Konferencyjne / Research and Technical Papers of Polish Association and Transportation Engineers in Cracow: Series: Proceedings*, (148), 57–73.
- El Esawey, M., Sayed, T. (2011). Calibration and validation of micro-simulation models of medium-size networks. *Advances in Transportation Studies: An International Journal: Section B*, 24, 57–76. <https://www.atsinternationaljournal.com/2011-issues/calibration-and-validation-of-micro-simulation-models-of-medium-size-networks/>
- Fellendorf, M., Vortisch, P. (2011). Microscopic traffic flow simulator VISSIM. W: J. Barceló (red.), *Fundamentals of traffic simulation* (s. 63–93). Springer. [https://doi.org/10.1007/978-1-4419-6142-6\\_2](https://doi.org/10.1007/978-1-4419-6142-6_2)
- Florida Department of Transportation. (2014, marzec). *Traffic analysis handbook: A reference for planning and operations*. [https://fdotwww.blob.core.windows.net/sitefinity/docs/default-source/planning/systems/systems-management/sm-old-files/traffic-analysis/traffic-analysis-handbook\\_march-2014.pdf?sfvrsn=51c88e22\\_0](https://fdotwww.blob.core.windows.net/sitefinity/docs/default-source/planning/systems/systems-management/sm-old-files/traffic-analysis/traffic-analysis-handbook_march-2014.pdf?sfvrsn=51c88e22_0)
- Friedrich, M., Pestel, E., Schiller, C., Simon, R. (2019). Scalable GEH: A quality measure for comparing observed and modeled single values in a travel demand model validation. *Transportation Research Record: Journal of the Transportation Research Board*, 2673(4), 722–732. <https://doi.org/10.1177/0361198119838849>
- Gaca, S., Suchorzewski, W., Tracz, M. (2014). *Inżynieria ruchu drogowego. Teoria i praktyka*. Wydawnictwa Komunikacji i Łączności.

- Gitahi, J., Hahn, M., Storz, M., Bernhard, C., Feldges, M., Nordentoft, R. (2020). Multi-sensor traffic data fusion for congestion detection and tracking. *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, XLIII-B1-2020, 173–180. <https://doi.org/10.5194/isprs-archives-XLIII-B1-2020-173-2020>
- Hafram, S., Valery, S., Hasim, A. (2023). Calibrating and validation microscopic traffic simulation models VISSIM for enhanced highway capacity planning. *International Journal of Engineering: Transactions B: Applications*, 36(8), 1509–1519. <https://doi.org/10.5829/ije.2023.36.08b.11>
- Hellinga, B.R. (1998). *Requirements for the calibration of traffic simulation models* [wystąpienie konferencyjne, Canadian Society for Civil Engineering 1998 Annual Conference, Halifax, Nowa Szkocja]. University of Waterloo – Dr. Bruce Hellinga [publikacje autora]. <https://www.civil.uwaterloo.ca/bhellinga/publications/Publications/CSCE-1998-Calibration.PDF>
- Hidas, P., Wagner, P. (2004). *Review of data collection methods for microscopic traffic simulation* [wystąpienie konferencyjne, 10th World Conference on Transport Research, Stambuł]. WCTRS. <https://www.wctrs-society.com/wp-content/uploads/abstracts/istanbul/125.pdf>
- Ishaque, M.M., Noland, R.B. (2009). Pedestrian and vehicle flow calibration in multimodal traffic microsimulation. *Journal of Transportation Engineering*, 135(6), 338–348. [https://doi.org/10.1061/\(ASCE\)0733-947X\(2009\)135:6\(338\)](https://doi.org/10.1061/(ASCE)0733-947X(2009)135:6(338))
- Jamroz, K., Budziszewski, T., Kustra, W., Birr, K., Romanowska, A., Maciasz, K., Zawisza, M. (2012, 4 września). *Transportowy model symulacyjny miasta Gdańska* [prezentacja PowerPoint]. Portal Miasta Gdańska. <https://www.gdansk.pl/urzed-miejski/wiadomosci/powstal-transportowy-model-symulacyjny-miasta-gdanska,a,26094>
- Karimi, M., Miriastabanati, M., Esmaeeli, H., Alecsandru, C. (2019). Multi-objective stochastic optimization algorithms to calibrate microsimulation models. *Transportation Research Record: Journal of the Transportation Research Board*, 2673(4), 743–752. <https://doi.org/10.1177/0361198119838260>
- Klos, M.J., Sobota, A. (2019). Performance evaluation of roundabouts using a microscopic simulation model. *Scientific Journal of Silesian University of Technology. Series Transport / Zeszyty Naukowe Politechniki Śląskiej. Seria Transport*, 104, 57–67. <https://doi.org/10.20858/sjsutst.2019.104.6>
- Kowalski, M., Wiśniewski, S. (2017). Natężenie ruchu a zagospodarowanie Łodzi – zarys problematyki w świetle danych z Obszarowego Systemu Sterowania Ruchem. *Prace Komisji Geografii Komunikacji PTG*, 20(4), 20–36. <https://doi.org/10.4467/2543859XPKG.17.022.8028>
- Kucharski, R. (2009). Metoda detekcji cellular floating data – możliwości i perspektywy. *Zeszyty Naukowo-Techniczne Stowarzyszenia Inżynierów i Techników Komunikacji Rzeczypospolitej Polskiej. Oddział w Krakowie. Seria: Materiały Konferencyjne / Research and Technical Papers of Polish Association and Transportation Engineers in Cracow: Series: Proceedings*, (148), 143–153.
- Lownes, N.E., Machemehl, R.B. (2006). VISSIM: A multi-parameter sensitivity analysis. W: L.F. Perrone, B.G. Lawson, J. Liu i F.P. Wieland (red.), *Proceedings of the 2006 Winter Simulation Conference* (s. 1406–1413). IEEE. <https://doi.org/10.1109/WSC.2006.323241>
- Manjunatha, P., Vortisch, P., Mathew, T.V. (2013, styczeń). Methodology for the calibration of VISSIM in mixed traffic. *ResearchGate*. [https://www.researchgate.net/publication/281290567\\_Methodology\\_for\\_the\\_Calibration\\_of\\_VISSIM\\_in\\_Mixed\\_Traffic](https://www.researchgate.net/publication/281290567_Methodology_for_the_Calibration_of_VISSIM_in_Mixed_Traffic)
- Mężyk, A., Zamkowska, S. (2019). *Problemy transportowe miast. Stan i kierunki rozwiązań*. Wydawnictwo Naukowe PWN.
- Miejska Pracownia Urbanistyczna w Łodzi. (2018). *Studium uwarunkowań i kierunków zagospodarowania przestrzennego miasta Łodzi – 2018*. <https://mpu.lodz.pl/opracowania/studium/>
- Mohan, R., Eldhose, S., Manoharan, G. (2021). Network-level heterogeneous traffic flow modelling in VISSIM. *Transportation in Developing Economies*, 7(1), artykuł 8. <https://doi.org/10.1007/s40890-021-00117-4>
- Mosseri, G.M.S., Hall, M.A., Rivera, J.M. (2004). *Lincoln tunnel corridor study: Traffic micro-simulation* [abstrakt wystąpienia konferencyjnego, ITE 2004 Annual Meeting and Exhibit, Lake Buena Vista]. The National Academies of Sciences, Engineering, and Medicine – Transportation Research Board. <https://trid.trb.org/View/744406>
- Otković, I.I., Deluka-Tibljša, A., Šurdonja, S. (2020). Validation of the calibration methodology of the micro-simulation traffic model. *Transportation Research Procedia*, 45, 684–691. <https://doi.org/10.1016/j.trpro.2020.02.110>
- Otković, I.I., Tollazzi, T., Šraml, M. (2013). Calibration of microsimulation traffic model using neural network approach. *Expert Systems with Applications*, 40(15), 5965–5974. <https://doi.org/10.1016/j.eswa.2013.05.003>
- Park, B.(B.), Qi, H.(M.). (2005). Development and evaluation of a procedure for the calibration of simulation models. *Transportation Research Record: Journal of the Transportation Research Board*, 1934(1), 208–217. <https://doi.org/10.1177/0361198105193400122>
- Park, B.(B.), Schneeberger, J.D. (2003). Microscopic simulation model calibration and validation: Case study of VISSIM simulation model for a coordinated actuated signal system. *Transportation Research Record: Journal of the Transportation Research Board*, 1856(1), 185–192. <https://doi.org/10.3141/1856-20>
- Park, B.(B.), Won, J. (2006a). Application of microscopic simulation model calibration and validation procedure: Case study of coordinated actuated signal system. *Transportation Research Record: Journal of the Transportation Research Board*, 1978(1), 113–122. <https://doi.org/10.1177/0361198106197800115>
- Park, B.(B.), Won, J. (2006b). *Microscopic simulation model calibration and validation handbook*. Virginia Transportation Research Council. <https://rosap.nrl.bts.gov/view/dot/19808>
- Rahman, M.H., Abdel-Aty, M., Lee, J., Rahman, M.S. (2019). Enhancing traffic safety at school zones by operation and engineering countermeasures: A microscopic simulation approach. *Simulation Modelling Practice and Theory*, 94, 334–348. <https://doi.org/10.1016/j.simpat.2019.04.001>
- Rrecaj, A.A., Bombol, K.M. (2015). Calibration and validation of the VISSIM parameters: State of the art. *TEM Journal*, 4(3), 255–269. [https://www.temjournal.com/content/43/05/TemJournalAugust2015\\_255\\_269.pdf](https://www.temjournal.com/content/43/05/TemJournalAugust2015_255_269.pdf)
- Siwek, K. (2024, 26 listopada). Marathon on Maratońska Street: Simulating future traffic in Łódź. *PTV Group*. <https://blog.ptvgroup.com/en/modeling-planning/marathon-on-maratońska-street-simulating-future-traffic-in-lodz/>
- So, J., Ostojic, M., Jolovic, D., Stevanovic, A. (2016, styczeń). Building, calibrating, and validating a large-scale high-fidelity microscopic traffic simulation model: A manual approach. *ResearchGate*. [https://www.researchgate.net/publication/303911902\\_Building\\_Calibrating\\_and\\_Validating\\_A\\_Large-Scale\\_High-Fidelity\\_Microscopic\\_Traffic\\_Simulation\\_Model\\_-\\_A\\_Manual\\_Approach](https://www.researchgate.net/publication/303911902_Building_Calibrating_and_Validating_A_Large-Scale_High-Fidelity_Microscopic_Traffic_Simulation_Model_-_A_Manual_Approach)
- Sokołowicz, M.E. (2013). Wokół koncepcji zrównoważonego transportu. Ślepe tory polemiki. *Kronika Miasta Łodzi*, 62(2), 17–24. <https://bc.wbp.lodz.pl/dlibra/publication/110518/edition/105663/content>
- Sroczyński, A. (2023). *Adaptacyjny system sterowania ruchem drogowym* [rozprawa doktorska, Politechnika Gdańska]. Most Wiedzy. <https://mostwiedzy.pl/pl/publication/adaptacyjny-system-sterowania-ruchem-drogowym,163123-1>
- Stevanovic, J., Stevanovic, A., Martin, P., Bauer, T. (2008). Stochastic optimization of traffic control and transit priority settings in VISSIM. *Transportation Research Part C: Emerging Technologies*, 16(3), 332–349. <https://doi.org/10.1016/j.trc.2008.01.002>

- SISKOM – Stowarzyszenie Integracji Stołecznej Komunikacji. (2025). *Aglomeracja warszawska. Studia komunikacyjne*. <https://siskom.waw.pl/planistyka-aglomeracja-sk.htm>
- TomTom. (2023). *Move*. Pobrane 21 stycznia 2025 r. z: <https://move.tomtom.com>
- TomTom. (2024). *TomTom Traffic Index* [kategoria: Łódź. Ruch uliczny]. <https://www.tomtom.com/traffic-index/lodz-traffic/>
- Washington State Department of Transportation. (2014, September). *Protocol for VISSIM simulation*. <https://wsdot.wa.gov/sites/default/files/2021-03/TrafficOps-VISSIM-Protocol.pdf>
- Wesołowski, J. (2013). Transportowe problemy Łodzi. Plany, drogi, motywacje. *Kronika Miasta Łodzi*, 62(2), 45–55. <https://bc.wbp.lodz.pl/dlibra/publication/110518/edition/105663/content>
- Yang, Y., Qin, Y., Dong, H., Zhang, Q. (2016). Parameter calibration method of microscopic traffic flow simulation models based on orthogonal genetic algorithm. W: G. Polese i V. Deufamia (red.), *Proceedings of the 22nd International Conference on Distributed Multimedia Systems (DMS 2016)* (s. 55–60). KSI Research.
- Żochowska, R., Karoń, G. (2012). Przegląd literatury na temat zjawiska kongestii i zakłóceń ruchu w systemie transportowym miasta w aspekcie modelowania podróży. *Zeszyty Naukowo-Techniczne Stowarzyszenia Inżynierów i Techników Komunikacji Rzeczypospolitej Polskiej. Oddział w Krakowie*, (2(98)), 251–276. <https://bibliotekanauki.pl/articles/249363.pdf>

Artykuł wpłynął:  
22 lutego 2025 r.  
Zaakceptowano do druku:  
30 czerwca 2025 r.



© by the author, licensee University of Lodz – Lodz University Press, Lodz, Poland. This article is an open access article distributed under the terms and conditions of the Creative Commons Attribution license CC-BY-NC-ND 4.0 (<https://creativecommons.org/licenses/by-nc-nd/4.0/>)

**Funding information:** Lodz University of Technology. **Conflicts of interests:** None. **Ethical considerations:** The Authors assure of no violations of publication ethics and take full responsibility for the content of the publication. **The percentage share of the author in the preparation of the work is:** M.K. 60%, K.U. 40%. **Declaration regarding the use of GAI tools:** M.K. used ChatGPT Deep Research, Gemini Deep Research, SciSpace Literature Review, Consensus Deep Research, Elicit Research report, Litmaps for the purpose of literature review and searching for related articles. The tools were provided with detailed prompts focusing on the search for scientific literature in the fields of spatial planning, traffic engineering, and computer microsimulation. The Author then carried out a thorough and critical review of the text, with particular attention to potential false, incomplete, or biased information, possible plagiarism or lack of proper/accurate authorship attribution, and revised it accordingly.